

Réunion 14 Avril- 28 mai

Pour quantifier l'effet batch dans nos données brutes, nous utilisons la régression sur composantes principales (PCR), une méthode standardisée par le framework scIB.

En pratique, on évalue dans quelle mesure le batch (B) influence chaque composante principale (PC_i) au moyen d'une régression linéaire, ce qui donne un coefficient de détermination $R^2(PC_i | B)$. On pondère ensuite ce R^2 par le ratio de variance propre à la composante concernée, noté $Var(C | PC_i)$.

La variance totale causée par le batch sur la matrice de données C s'obtient simplement en sommant le produit de ces contributions sur l'ensemble des G composantes retenues :

$$Var(C|B) = \sum_{i=1}^G Var(C|PC_i) \times R^2(PC_i|B)$$

(Adapté de : Luecken, M.D., et al. "Benchmarking atlas-level data integration in single-cell genomics." Nature Methods 19, 41–50 (2022). Supplementary Information: "Principal component regression").

Indice de Gini des classes

L'indice de Gini mesure le déséquilibre de composition cellulaire d'un dataset, à partir du nombre de cellules dans chaque type cellulaire. Il prend en compte toute la distribution des classes, pas seulement la classe la plus fréquente et la plus rare.

Formule utilisée, avec les effectifs de classes triés par ordre croissant :

$$\text{Gini} = [\sum_i (2i - n - 1) x_i] / [n \sum_i x_i]$$

où :

x_i = effectif de la classe i

n = nombre total de classes

i = rang de la classe après tri croissant

Interprétation :

Gini = 0 → classes parfaitement équilibrées

Gini élevé → quelques classes dominant, tandis que d'autres sont rares


Ainsi, un Gini élevé indique un dataset fortement déséquilibré en types cellulaires.

Jeu de données	Étude 1 (scCluBench)	Étude 2 (DESC)	Étude 3 (scSCCNIA)
Human testis	Oui	Non	Non
Kang PBMC	Non	Oui	Non
Macaque retina bipolar	Non	Oui	Non
Monocytes	Non	Oui	Non
Human Pancreas (OpenPr	Non	Potentiel	Non
Paul15 bone marrow	Non	Oui	Non
Tabula Muris liver	Oui	Non	Non
BBAG094 Zeisel	Oui	Non	Oui
BBAG094 spleen	Oui	Non	Oui
SCIB Human Pancreas 1	Oui	Non	Non
SCIB Human Pancreas 2	Oui	Non	Non
SCIB Mouse Pancreas 1	Oui	Non	Non
Baron human pancreas	Oui	Non	Non

Zeisel

PCR sur PCA
= 0.499

Distribution des classes cellulaires — BBAG094 Zeisel



Tissu : Cortex et hippocampe de souris

Technologie : Fluidigm C1 / C1-STRT (UMI)


En bref : 3 006 cellules, 10 types neuronaux et gliaux.
Cas particulier : chaque plaque Fluidigm capture un seul type cellulaire → les IDs de batch et les labels sont parfaitement confondus.

Classes rares (<5%) : unknown, 8, 9, 5

Classes ultra-rares (<1%) : unknown, 8

Human testis GSE112013

PCR sur PCA
= 0.024999



Tissu : Testicule humain

Technologie : 10x Genomics
Chromium 3' v2


En bref : 6 490 cellules
issues de 3 donneurs
séquencés en duplicat (2
réplicats/donneur). Couvre
13 types cellulaires du
processus de
spermatogenèse
(spermatogonies →
spermatozoïdes). Batch =
individu × réplicat.

Classes rares (<5%) : Sertoli, SSC, Late_spermatocyte, Spermatogonia

Classes ultra-rares (<1%) : Sertoli

Kang PBMC

PCR sur PCA
= 0.069024



Classes rares (<5%) : Dendritic cells

Classes ultra-rares (<1%) : Megakaryocytes

Tissu : Cellules mononucléées du sang périphérique (PBMC), humain


Technologie : 10x Genomics Chromium (droplet)

En bref : 24 679 cellules de 8 patients lupiques, chacun mesuré dans 2 conditions : contrôle (*ctrl*) et stimulé à l'interféron- β (*stim*). 8 types immunitaires (T CD4+, T CD8+, monocytes...). Batch = combinaison donneur $\times$ condition (*confoundedbatch*).

Pancreas

PCR sur PCA
= 0.153014

Distribution des classes cellulaires — Pancreas



Classes rares (<5%) : t_cell, schwann, epsilon, mast, macrophage, quiescent_stellate, endothelial, activated_stellate, gamma

Classes ultra-rares (<1%) : t_cell, schwann, epsilon, mast, macrophage


Tissu : Pancréas humain

Technologie : inDrop +
CEL-Seq + CEL-Seq2 +
Fluidigm C1 + Smart-seq2

En bref : 16 400 cellules, 14 types (alpha, beta, ductal...). Benchmark multi-protocoles : mêmes types cellulaires séquencés avec 5 technologies différentes réparties en 8 batches. Idéal pour tester la correction inter-protocoles.

Paul15 bone marrow

PCR sur PCA
= 0




Tissu : Moelle osseuse de souris

Technologie : MARS-seq

En bref : 2 730 cellules, 19 types correspondant à des stades de différenciation hématopoïétique (érythrocytes, monocytes, granulocytes...). Aucun batch : tout provient d'un seul lot. Dataset de référence classique pour l'étude des trajectoires de différenciation.

Tabula Muris liver

PCR sur PCA
= 0



Tissu : Foie de souris

Technologie : FACS +
Smart-seq2


En bref : 2 859 cellules, 11
types hépatiques
(hépatocytes, cellules de
Kupffer, endothéliales...).
Extrait de l'atlas
pan-tissulaire Tabula Muris.
Un seul batch

Classes rares (<5%) : neutrophil, CD4-positive, alpha-beta T cell, NK cell, T cell, CD8-positive, alpha-beta T cell

Classes ultra-rares (<1%) : Aucune

spleen

PCR sur PCA
= 0.0222



Classes rares (<5%) : dendritic cell, natural killer cell, macrophage

Classes ultra-rares (<1%) : dendritic cell

Tissu : Rate de souris


Technologie : 10x Genomics

En bref : 9 552 cellules, 5 types immunitaires (B, T, NK, macrophages, dendritiques). Seulement 2 batches : un individu mâle de 8 semaines (3-M-8) et une femelle de 56 semaines (3-F-56) → batch confondu avec le sexe et l'âge.

Mouse Pancreas 1

PCR sur PCA
= 0

Distribution des classes cellulaires — SCIB Mouse Pancreas 1



Classes rares (<5%) : B_cell, schwann, T_cell, activated_stellate, immune_other, alpha, gamma, macrophage, quiescent_stellate

Classes ultra-rares (<1%) : B_cell, schwann, T_cell, activated_stellate, immune_other

Tissu : Pancréas de souris
— donneur 1


Technologie : inDrop

En bref : 822 cellules, 13 types. Version murine du benchmark inDrop. Le plus petit dataset de la sélection. Un seul batch, nombreuses classes ultra-rares.

Baron human pancreas

PCR sur PCA
= 0.047784

Distribution des classes cellulaires — Baron human pancreas



Tissu : Pancréas humain

Technologie : inDrop

En bref : 8 569 cellules, 14 types, 4 donneurs (human1–4). Dataset de référence historique pour le pancréas (Baron et al. 2016). Batch = donneur. Souvent utilisé comme référence d'annotation pour les autres datasets pancréatiques.


Classes rares (<5%) : t_cell, schwann, epsilon, mast, macrophage, quiescent_stellate, endothelial, gamma, activated_stellate

Classes ultra-rares (<1%) : t_cell, schwann, epsilon, mast, macrophage

macaque retina bipolar

PCR sur PCA
= 0.184159

Distribution des classes cellulaires — Macaque retina bipolar



Classes rares (<5%) : OFFx, DB3a, DB6, DB1

Classes ultra-rares (<1%) : OFFx

Tissu : Rétine de macaque
— cellules bipolaires

Technologie : 10x Genomics
Chromium 3' v2

En bref : 30 302 cellules, 12 sous-types de cellules bipolaires. Design imbriqué : captures multiples par macaque (M1–M4) × région rétinienne (Fovea, Periphery). 30 batches au total → fort effet batch.

Effet Batch NUL ($\text{PCR} < 0.01$) : Jeux de données provenant d'une seule étude, sans intégration nécessaire (ex: Paul15, SCIB Pancreas 1/2).

Effet Batch FAIBLE / MODÉRÉ ($0.01 < \text{PCR} < 0.10$) : Intégration de quelques donneurs ou réplicats techniques sur une technologie unique (ex: Kang PBMC à 0.06, Spleen à 0.02).

Effet Batch ÉLEVÉ ($\text{PCR} > 0.10$) : Intégration multi-technologies ou multi-études avec un fort bruit technique (ex: Pancreas Merged à 0.15, Macaque Retina à 0.18).

Effet Batch EXTRÊME ($\text{PCR} > 0.40$) : Cas de confusion totale (ex: Zeisel à 0.49).

Déséquilibre FAIBLE ($Gini < 0.45$) : Les types cellulaires sont répartis de manière relativement homogène ; aucune population n'écrase statistiquement les autres (ex: Human Testis à 0.30, Macaque Retina à 0.39, Paul15 à 0.41).

Déséquilibre MODÉRÉ ($0.45 < Gini < 0.60$) : Une structure asymétrique commence à apparaître avec une ou deux classes nettement plus fréquentes (ex: Kang PBMC à 0.50, Tabula Muris Liver à 0.58).

Déséquilibre ÉLEVÉ ($0.60 < Gini < 0.70$) : Forte asymétrie biologique. Plusieurs populations sont "rares" (<5%) face à un bloc majoritaire (ex: Pancreas Merged à 0.65, Baron Pancreas à 0.64).

Déséquilibre EXTRÊME ($Gini > 0.70$) : Cas de "l'aiguille dans la botte de foin". Une classe ultra-dominante coexiste avec des populations quasi-indétectables (ex: SCIB Mouse Pancreas 1 à 0.71, SCIB Human Pancreas 2 à 0.70).

Indice de Gini des classes

L'indice de Gini mesure le déséquilibre de composition cellulaire d'un dataset, à partir du nombre de cellules dans chaque type cellulaire. Il prend en compte toute la distribution des classes, pas seulement la classe la plus fréquente et la plus rare.

Formule utilisée, avec les effectifs de classes triés par ordre croissant :

$$\text{Gini} = [\sum_i (2i - n - 1) x_i] / [n \sum_i x_i]$$

où :

x_i = effectif de la classe i

n = nombre total de classes

i = rang de la classe après tri croissant

Interprétation :


Gini = 0 → classes parfaitement équilibrées

Gini élevé → quelques classes dominant, tandis que d'autres sont rares


Ainsi, un Gini élevé indique un dataset fortement déséquilibré en types cellulaires.

Dataset	Gini	PCR_on_PCA	Gini_Category	PCR_Category
Human testis GSE112013	0,304	0,025	Faible	Faible / Modéré
Kang PBMC	0,5	0,069	Modéré	Faible / Modéré
Macaque retina bipolar	0,388	0,184	Faible	Élevé
Human Pancreas (OP) 4 batches	0,651	0,156	Élevé	Élevé
Paul15 bone marrow	0,41	0	Faible	Nul
Human Pancreas (OpenProblems)	0,655	0,153	Élevé	Élevé
Tabula Muris liver	0,578	0	Modéré	Nul
BBAG094 Zeisel	0,543	0,499	Modéré	Extrême
BBAG094 spleen	0,644	0,022	Élevé	Faible / Modéré
SCIB Human Pancreas 1	0,636	0	Élevé	Nul
SCIB Human Pancreas 2	0,701	0	Extrême	Nul
SCIB Mouse Pancreas 1	0,711	0	Extrême	Nul
Baron human pancreas	0,644	0,048	Élevé	Faible / Modéré


450 trials, que le jeu de donnée Baron




Hyperparameter Importances (mean of seeds 0-4, top 30)



80 TRIALS, 8 DATASETS (



18 TRIALS, 13 DATASETS (espace de recherche plus restreint basé sur les meilleurs trials de la run à 80 trials.)



2 configurations

	Hyperparamètre	Rôle court	Type	Version A	Version B	Statut	Delta numérique
0	Latent dimension z	dimension de l'espace latent	Numérique	192	256	Oui	-64.000
1	Total epochs	nombre total d'époques	Numérique	210	120	Oui	+90.000
2	Phase 1 epochs	durée du warm-up initial	Numérique	74	55	Oui	+19.000
3	Masking rate	fraction des gènes masqués	Numérique	0.15	0.1	Oui	+0.050
4	gamma_cluster	exposant de la taille de cluster	Numérique	0.7	0.2	Oui	+0.500
5	Clip max of omega_dens	plafond du poids basé sur la densité	Numérique	8	3	Oui	+5.000
6	Weight update interval (epochs)	fréquence de recalcul des poids	Numérique	10	20	Oui	-10.000
7	Max omega_i	borne haute du poids par cellule	Numérique	8	10	Oui	-2.000
8	Omega fusion mode	mode de fusion taille/densité	Catégoriel	Addition	Multiplification	Oui	—
9	Triplet start epoch	époque d'activation du triplet	Numérique	84	60	Oui	+24.000
10	Triplet anchor min omega_i	seuil minimal pour une ancre rare	Numérique	1.8	1.2	Oui	+0.600
11	HDBSCAN min_samples	nombre minimal de voisins HDBSCAN	Numérique	8	6	Oui	+2.000
12	HDBSCAN noise reassignment	réaffectation des points bruités	Numérique	1	0	Oui	+1.000
13	GRL lambda (lambda_GRL)	force du gradient reversal DANN	Numérique	1.75	1	Oui	+0.750
14	DANN start epoch	début de la branche DANN	Numérique	55	30	Oui	+25.000
15	DANN ramp epochs	durée de montée de DANN	Numérique	60	30	Oui	+30.000
16	Learning rate eta	taux d'apprentissage de l'optimiseur	Numérique	0.002	0.002	Oui	+0.001
17	NB dispersion theta	dispersion du modèle NB	Numérique	2.582	19.238	Oui	-16.656
18	lambda_triplet	poids de la perte triplet	Numérique	0.235	0.05	Oui	+0.185
19	lambda_batch	poids de la perte adversariale batch	Numérique	0.056	0.118	Oui	-0.061
20	alpha (cluster vs density)	compromis taille de cluster / densité	Numérique	0.3	0.348	Oui	-0.048
21	Omega update momentum	inertie EMA des poids de cellule	Numérique	0.85	0.688	Oui	+0.162

A = default (jobim)

B = Run la + stable identifiée


Différence + et x

RARETÉ (C_I)	ISOLATION (D_I)	Résultat ADDITIF	Résultat MULTIPLICATIF
Haut	Haut	● Très Haut	● Extrême (Amplifié)
Haut	Bas	● Moyen (Signal conservé)	● Bas (Sanction)
Bas	Haut	● Moyen (Signal conservé)	● Bas (Sanction)
Bas	Bas	● Bas	● Nul/Min (Plancher)

EVALUATION METRICS

Métrique de clustering

$$ARI = \frac{\text{Index} - \text{ExpectedIndex}}{\text{MaxIndex} - \text{ExpectedIndex}}$$



Métrique de reconnaissance des types cellulaires

$$\text{BalancedAccuracy} = \frac{1}{K} \sum_{k=1}^K \frac{TP_k}{TP_k + FN_k}$$

$$\text{RareACC} = \frac{\text{Correct predictions on rare cells}}{\text{Total number of rare cells}}$$

Métrique de l' batch

scIB-E batch
mean(Silhouette
batch, iLISI, KB
Graph connectiv

1.1 1. Silhouette batch (ASW batch)

Concept : Cette métrique évalue le mélange des lots en mesurant la distance entre les cellules d'un même lot par rapport aux cellules d'autres lots. Le calcul est restreint à l'intérieur d'un même type cellulaire pour ne pas pénaliser la séparation biologique.

Formule de la largeur de silhouette $s(i)$:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$: distance moyenne entre la cellule i et toutes les autres cellules de son **même lot**.
- $b(i)$: distance moyenne minimale entre la cellule i et les cellules d'un **autre lot**.

Score final scIB :

$$ASW_{batch_score} = 1 - |ASW_{batch}|$$

Une valeur de 1 représente un mélange optimal.

1.2 2. iLISI (integration LISI)

Concept : L'iLISI (*integration Local Inverse Simpson's Index*) mesure le nombre effectif de lots différents présents dans le voisinage immédiat d'une cellule.

Formule LISI(x) pour une cellule x :

$$LISI(x) = \frac{1}{\sum_{b=1}^B p(b|x)^2}$$

- $\sum$: somme sur tous les lots b .
- $p(b|x)$: proportion (pondérée par la distance) du lot b dans le voisinage local de x .

Score final normalisé :

$$iLISI_{score} = \frac{LISI - 1}{B - 1}$$

- B : nombre total de lots dans le jeu de données.

Un score de 1 indique un mélange parfait des lots dans chaque voisinage.

1.3 3. KBET (k-nearest-neighbour Batch Effect Test)

Concept : Test statistique qui vérifie si la répartition des lots dans le voisinage local d'une cellule est indiscernable de la répartition globale des lots dans tout le jeu de données.

Formule du test (Chi-carré) :

$$\chi^2 = \sum_{b=1}^B \frac{(O_b - E_b)^2}{E_b}$$

- O_b : nombre observé de cellules du lot b dans le voisinage.
- E_b : nombre attendu de cellules du lot b (fréquence globale).

Score final scIB :

$$kBET_{score} = 1 - \left(\frac{\text{Nombre de voisinages rejetés}}{\text{Nombre total de voisinages}} \right)$$

Un score proche de 1 signifie que la majorité des voisinages reflètent la distribution globale.

1.4 4. Graph connectivity (Connectivité du graphe)

Concept : Vérifie si toutes les cellules d'une même identité biologique sont connectées de manière contiguë dans le graphe des plus proches voisins (kNN). Cela s'assure que l'intégration n'a pas fracturé un type cellulaire à cause de l'effet de lot.


Formule de connectivité globale (GC) :

$$GC = \frac{1}{|C|} \sum_{c \in C} \frac{|LCC(subgraph_c)|}{|c|}$$

- $|C|$: ensemble des types cellulaires.
- $|c|$: nombre total de cellules appartenant au type c .
- $|LCC(subgraph_c)|$: nombre de cellules dans la plus grande composante connexe (*Largest Connected Component*) du sous-graphe du type c .

Un score de 1 signifie que pour chaque type, toutes les cellules forment un réseau unique et connecté.

Harmony



La PCA projette les cellules dans un espace de dimension réduite. Harmony prend les coordonnées des cellules dans cet espace réduit et applique un algorithme itératif afin de corriger les effets spécifiques aux jeux de données.

a. Harmony utilise un clustering flou (*fuzzy clustering*) pour attribuer chaque cellule à plusieurs clusters, tandis qu'un terme de pénalité garantit que la diversité des jeux de données au sein de chaque cluster est maximisée.

b. Harmony calcule un centroïde global pour chaque cluster, ainsi que des centroïdes spécifiques à chaque jeu de données pour chaque cluster.

c. Au sein de chaque cluster, Harmony calcule un facteur de correction pour chaque jeu de données à partir des centroïdes.

d. Enfin, Harmony corrige chaque cellule avec un facteur spécifique à cette cellule : il s'agit d'une combinaison linéaire des facteurs de correction des jeux de données, pondérée par les assignations souples de la cellule aux clusters réalisées à l'étape a.

Harmony répète les étapes a à d jusqu'à convergence. La dépendance entre l'assignation aux clusters et le jeu de données diminue à chaque itération. Les jeux de données sont représentés par des couleurs, et les types cellulaires par différentes formes.

Combat

Negative binomial regression models

Gene-wise model: for a certain gene g , count in sample j from batch i $y_{gij} \sim NB(\mu_{gij}, \phi_{gi})$

$$\log \mu_{gij} = \alpha_g + X_j \beta_g + \gamma_{gi} + \log N_j$$

$$Var(y_{gij}) = \mu_{gij} + \phi_{gi} \mu_{gij}^2$$

Decompose scaled counts into 3 components

- α_g Average level for gene g (in "negative" samples)
- $X_j \beta_g$ Biological condition of sample j
- γ_{gi} Mean batch effect
- ϕ_{gi} Dispersion batch effect

Estimate batch effect parameters

Estimate parameters using established methods in edgeR

Calculate "batch-free" distributions


We assume the adjusted data also follow a negative binomial distribution: $y_{gj}^* \sim NB(\mu_{gj}^*, \phi_g^*)$

$$\log \mu_{gj}^* = \log \hat{\mu}_{gij} - \hat{\gamma}_{gi}$$

$$\phi_g^* = \frac{1}{N_{batch}} \sum_i \hat{\phi}_{gi}$$

Adjust the data

Mapping the data from the estimated empirical distributions to "batch-free" distributions




. Elle repose sur un modèle d'**empirical Bayes**, c'est-à-dire une approche qui estime les effets de batch en empruntant de l'information à l'ensemble des gènes afin de stabiliser les estimations, notamment quand les effectifs par batch sont faibles.

L'effet de batch est généralement séparé en deux types d'effets. Le premier est un effet additif : par exemple, un batch peut augmenter globalement l'expression mesurée d'un gène. Le second est un effet multiplicatif ou d'échelle : un batch peut augmenter la variance ou l'amplitude des valeurs d'expression.

ComBat estime donc, pour chaque gène et chaque batch, un décalage moyen et un facteur d'échelle, puis ajuste les données pour retirer ces effets techniques. L'approche empirical Bayes permet de rendre ces estimations plus robustes en évitant que chaque gène soit corrigé uniquement à partir de ses propres observations, ce qui serait instable avec peu d'échantillons.

Il existe aussi **ComBat-seq**, une extension pensée pour les données RNA-seq de comptage. Contrairement au ComBat classique, qui suppose plutôt des données continues approximativement gaussiennes, ComBat-seq utilise un modèle de régression binomiale négative et conserve la nature entière des counts.

SCANORAMA



Scanorama commence par réduire la dimension des données et cherche des cellules similaires entre datasets différents. Il utilise une logique proche des **mutual nearest neighbors** : si une cellule du dataset A est proche d'une cellule du dataset B, et que cette cellule du dataset B est aussi proche de la cellule du dataset A, alors ces deux cellules peuvent être considérées comme une correspondance fiable. Ces correspondances sont interprétées comme des cellules biologiquement similaires observées dans des batches différents.


Une fois ces correspondances trouvées, Scanorama estime des vecteurs de correction pour rapprocher les datasets. Il ne force pas forcément tous les datasets à se mélanger entièrement ; il aligne surtout les parties qui semblent biologiquement partagées. Scanorama semble recommandé pour les jeux de données avec des technologies différentes.

Effet batch Faible


Spleen

Moyennes par méthode sur le sous-ensemble filtré


ARI




BalancedACC




RareACC



UltraRareACC








Batch correction



Effet batch Fort

Pancreas (sans baron)


Moyennes par méthode sur le sous-ensemble filtré



Effet batch Fort


Macaque

ARI




Moyennes par méthode sur le sous-ensemble filtré


BalancedACC




RareACC



UltraRareACC








Batch correction



Déséquilibre Fort


pancreas (avec baron)

Moyennes par méthode sur le sous-ensemble filtré







Déséquilibre faible

Human Testis








Moyennes par méthode sur le sous-ensemble filtré




Effet Batch MAX / Déséquilibre Moyen : Zeisel (cas particulier)

Moyennes par méthode sur le sous-ensemble filtré




Effet Batch NUL / Déséquilibre EXTRÊME : SCIB Human Pancreas 2



- Une seule métriques de batch correction a fonctionné (


Effet Batch MODÉRÉ / Déséquilibre FAIBLE : Kang PBMC




Déséquilibre Élevé mais SANS Effet Batch : SCIB Mouse Pancreas 1

Moyennes par méthode sur le sous-ensemble filtré


ARI




BalancedACC




RareACC



UltraRareACC








Batch correction




Effet Batch Élevé mais SANS Déséquilibre Majeur : Macaque

Moyennes par méthode sur le sous-ensemble filtré




scRAW vs Autre Algos Rare specific



scCAD

scCAD fait d'abord un clustering global : PCA interne -> graphe kNN -> Louvain. Ce premier clustering sert à entraîner une RandomForest qui identifie des gènes importants. Ensuite scCAD garde l'union des HVG et des gènes importants par RandomForest, puis reclusterise/décompose les gros clusters en sous-clusters plus petits. Après ça, il fusionne les sous-clusters trop proches.

Le calcul de DEG arrive après cette étape de décomposition + fusion. Pour chaque cluster fusionné, scCAD cherche les gènes qui distinguent ce cluster du reste des cellules. Dans le code auteur, c'est fait par différence de médiane cluster vs reste, puis sélection des meilleurs gènes. Ces gènes servent ensuite à entraîner un Isolation Forest : si les cellules du cluster ressortent comme fortement "anormales" dans cet espace de gènes, le cluster reçoit un score d'indépendance élevé et peut être considéré comme rare.

A**scAIDE****B**

D'abord, scAIDE apprend une représentation réduite des cellules avec un module appelé AIDE.

La première est la loss de reconstruction, qui entraîne l'autoencodeur à reconstruire les profils d'expression des cellules.

La deuxième est la loss de préservation des distances (Lmds) Elle force l'espace latent à conserver les relations entre cellules : deux cellules proches dans les données d'expression doivent rester proches dans l'embedding, tandis que deux cellules différentes doivent rester éloignées.


La loss totale de AIDE est donc :

$$L(D_p; W_a, W_m) = L_{\text{rec}}(D_p; W_a) + \alpha L_{\text{mds}}(D_p; W_a, W_m),$$


Une fois cet embedding appris, scAIDE applique RPH-kmeans, une variante de k-means basée sur le random projection hashing. Cette méthode regroupe d'abord les cellules proches pour construire une version simplifiée du jeu de données, puis utilise cette structure pour mieux initialiser les centres de clusters. Cela limite le biais du k-means classique, qui a tendance à favoriser les grands groupes cellulaires, et améliore ainsi la détection des petites populations rares.

giniClust

Step1. Calculate Gini index




Step2. Normalize Gini index.
Select high Gini genes.




Step3. Identify rare cell clusters by DBSCAN



Step4. Visualization of results by using tSNE



Step5. Identify rare cell-type specific
gene signature



CellSIUS




CellSIUS est plus local. Il ne fabrique pas toute la structure globale comme scCAD. Il reçoit déjà des clusters initiaux, chez nous Leiden sur PCA ou Leiden sur Harmony. Ensuite, dans chaque cluster, il cherche des gènes bimodaux : ce sont des gènes qui divisent les cellules du cluster en deux groupes, par exemple un groupe où le gène est peu exprimé et un autre groupe où il est fortement exprimé. Ce type de profil peut indiquer qu'à l'intérieur du cluster, une petite sous-population possède une signature transcriptomique particulière.

Ensuite, CellSIUS ne garde pas tous les gènes bimodaux. Il filtre les gènes pour conserver surtout ceux qui sont spécifiques au cluster étudié, afin d'éviter de détecter des signaux trop généraux ou déjà présents ailleurs dans le jeu de données. Cela permet de se concentrer sur les signatures réellement locales, propres à un sous-groupe cellulaire.

Une fois ces gènes sélectionnés, CellSIUS regroupe les gènes qui varient ensemble. Pour cela, il utilise MCL, un algorithme de clustering de graphes. L'idée est que si plusieurs gènes sont corrélés entre eux, ils peuvent former une même signature transcriptomique. Au lieu de considérer chaque gène séparément, CellSIUS considère donc des groupes de gènes cohérents.

Enfin, CellSIUS calcule pour chaque cellule l'expression moyenne de ces groupes de gènes. Les cellules qui expriment fortement une signature donnée peuvent alors être séparées du reste du cluster et définies comme une sous-population rare ou atypique.

DeepSCENA



$$L_u^{(k)} = L_r^{(k)} + \alpha L_c^{(k)} + \beta L_{NB}^{(k)}$$

$$L_r^{(k)} = \sum_{i=1}^n p_{ik}^{\lambda} \|x_i - \hat{x}_i\|_2^2$$

$$L_c^{(k)} = \sum_{i=1}^n p_{ik}^{\lambda} \|u_i - u^{(k)}\|_2^2$$

$$L_{NB}^{(k)} = - \sum_{i=1}^n p_{ik}^{\lambda} \sum_{j=1}^t \log(P_{NB}([x_{ij}] | \mu, \theta))$$

$$p_{ik} = \left(\|u_i - u^{(k)}\|_2^{\frac{2}{\pi-1}} \right)^{-1} / \sum_{j=1}^K \left(\|u_i - u^{(j)}\|_2^{\frac{2}{\pi-1}} \right)^{-1}$$

$$u^{(k)} = \sum_{i=1}^n p_{ik}^m u_i / \sum_{i=1}^n p_{ik}^m$$

DeepScena apprend un espace latent spécialement organisé pour le clustering, puis raffine progressivement les grands clusters afin de faire apparaître des sous-populations rares. Contrairement à scRAW, il ne donne pas directement plus de poids aux cellules rares dans la loss ; il les détecte surtout grâce au raffinement hiérarchique, à la resélection des gènes variables et à l'amélioration des similarités entre cellules.

Ici, p_{ik} correspond à la probabilité que la cellule i appartienne au cluster k . Cette probabilité est utilisée comme poids dans les différentes losses.

À intervalles réguliers, les centres de clusters sont mis à jour dans l'espace latent. Les auteurs indiquent que les centres $u^{(k)}$ sont recalculés tous les T_1 epochs à partir des cellules pondérées par leur degré d'appartenance au cluster.

Comment se positionne scRAW face à ces algorithmes rare specific ?




Méthodes


scRNA/tis1 scRNA/tis2 scRNA/tis3 scRNA/tis4

Comment se positionne scRAW face à ces algorithmes rare specific ?

Moyennes par méthode sur le sous-ensemble filtré



Comment se positionne scRAW face à ces algorithmes rare specific ?




Comment se positionne scRAW face à ces algorithmes associé à une méthode de batch correction




Méthodes



Comment se positionne scRAW face à ces algorithmes associé à une méthode de batch correction




Comment se positionne scRAW face à ces algorithmes associé à une méthode de batch correction




Comment se débrouille scRAW avec Harmony sur des datasets sans effet batch (METTRE À JOUR DIFF DE SEED)

Moyennes par méthode sur le sous-ensemble filtré



Comment se débrouille scRAW sans le DANN sur des datasets sans effet batch


Grille par dataset et métrique (style article)



Effet scRAW inductif

Ultra Rare ACC by algorithm - dataset-level means


Each point is one dataset mean over available inductive splits.



Effet scRAW inductif

Rare ACC by algorithm - dataset-level means


Each point is one dataset mean over available inductive splits.



Effet scRAW inductif



ARI by algorithm - dataset-level means

Each point is one dataset mean over available inductive splits.




Effet transfert de loss

Comparaison des algorithmes et variantes




Effet transfert de loss

std mean sur Baron



scDeepCluster Warm-up = pretrain



Effect batch scMAE en inductif


Baron pancreas - scMAE inductif vs non-inductif

UMAP recalculé séparément sur les embeddings de chaque run; les couleurs montrent les labels ou les batches.


Labels

acinar	delta	ductal	epsilon	endothelial	macrophage	mast
beta	activated_stellate	alpha	gamma	quiescent_stellate	schwann	t_cell

Labels - inductif




Labels - non-inductif



Batches - inductif




Batches - non-inductif



Batches

human1	human2	human3	human4
--------	--------	--------	--------

Analyse bio



Identification des gènes marqueurs :

pour chaque cluster, les auteurs recherchent les gènes les plus spécifiquement exprimés avec `rank_genes_groups` de Scanpy.

Création d'une référence biologique :

les 100 meilleurs marqueurs des vrais types cellulaires sont utilisés comme référence.

Annotation des clusters prédits :

les marqueurs des clusters prédits sont comparés aux marqueurs des vrais types cellulaires.


Méthode "marker-overlap" :

un cluster est annoté selon le type cellulaire avec lequel il partage le plus de gènes marqueurs.

Umap avant après harmony

Préprocess → latent → Harmony → clustering

scMAE — Avant Harmony — batch



scMAE — Après Harmony — batch

