

Plan détaillé du rapport de stage

Benchmarking interactif, développement de scRAW et évaluation inductive pour le clustering scRNA-seq

Fabien Bidet

Avril 2026

Période : [Janvier-Juin 2026]

Structure d'accueil : [LaBRI]

Encadrant universitaire : [Patricia Thébault]

Tuteur de stage : [Victoria Bourgeais, Loann Giovannangeli]

Table des matières

Plan détaillé	2
Fil conducteur proposé	2
Question centrale possible	2
0.1 Introduction	2
0.2 Etat de l'art	3
0.3 Matériel et méthodes	4
0.3.1 Données et environnement expérimental	4
0.3.2 Logiciel interactif de benchmarking	5
0.3.3 Algorithmes de l'état de l'art testés	5
0.3.4 Description de scRAW	5
0.3.5 Recherche d'hyperparamètres	5
0.3.6 Tests pour rendre scRAW inductif	6
0.3.7 Métriques et analyses	6
0.3.8 Reproductibilité et traçabilité	6
0.4 Résultats et discussion	6
0.4.1 Résultat 1 : logiciel de benchmarking	6
0.4.2 Résultat 2 : comparaison des algorithmes existants	7
0.4.3 Résultat 3 : performances et comportement de scRAW	7
0.4.4 Résultat 4 : recherche d'hyperparamètres	7
0.4.5 Résultat 5 : premiers tests inductifs	7
0.4.6 Résultat 6 : analyse qualitative des clusters	7
0.4.7 Résultat 7 : coût de calcul et difficultés rencontrées	7
0.4.8 Discussion générale	8
0.5 Conclusion et perspectives	8
0.6 Figures et tableaux à préparer	8

Plan détaillé

Fil conducteur proposé

J'aimerais partir sur l'histoire suivante : partir du problème biologique et méthodologique, montrer pourquoi un benchmark était nécessaire, comparer les algorithmes existants, puis expliquer comment cette comparaison a motivé la création de scRAW, son optimisation par recherche d'hyperparamètres, le transfert de loss et les premiers tests pour le rendre inductif.

Question centrale possible

Question directrice : comment construire, évaluer et améliorer un pipeline de clustering scRNA-seq capable de mieux préserver les populations cellulaires rares ?

Cette question peut servir à relier tous les blocs du rapport :

- le benchmark répond au besoin de comparer proprement les méthodes ;
- l'état de l'art montre les forces et limites des approches existantes ;
- scRAW propose une réponse algorithmique centrée sur les populations rares ;
- la recherche d'hyperparamètres étudie la stabilité et les compromis ;
- l'inductif teste la capacité à passer d'une analyse fixée à un jeu de données à une prédiction sur de nouvelles données rendant l'application réelle encore plus concrète. Le transfert de loss peut permettre de transférer la loss de reconstruction pondérée à d'autres algorithmes de Deep Learning.

0.1 Introduction

Objectif de la section

Introduire le contexte scRNA-seq, le besoin de clustering et le problème spécifique des populations rares.

Points à traiter

- Rappeler ce que sont les données scRNA-seq et pourquoi elles sont importantes.
- Expliquer le rôle du clustering dans l'identification de types cellulaires.

- Introduire les difficultés : grande dimension, bruit, sparsity, batch effects, déséquilibre des populations.
- Formuler le problème central : les populations rares sont mal capturées par beaucoup de pipelines. L'effet batch perturbe le clustering plus il est important
- Donner un exemple biologique concret de population rare : cellule immunitaire minoritaire, sous-type tumoral, population pathologique ou population spécifique d'un tissu.
- Expliquer pourquoi rater une population rare peut avoir un impact biologique : perte d'un signal d'intérêt, confusion entre types proches, interprétation incomplète d'un tissu.
- Annoncer les contributions du stage : logiciel de benchmark, comparaison de l'état de l'art, création de scRAW, recherche d'hyperparamètres, tests inductifs, transfert de loss.

Autres éléments à inclure

- Mentionner que le clustering est souvent une étape amont pour l'annotation cellulaire et l'analyse biologique.
- Introduire l'élément fort de notre algorithme qui est l'équilibre entre performance globale et détection des petites populations.
- Parler de l'intérêt de la reproductibilité et de son application réelle dans l'analyse bioinformatique.

0.2 Etat de l'art

Plan possible

1. Prétraitement des données scRNA-seq

- filtrage cellules/gènes, normalisation, log-transformation, HVG, scaling ;
- importance de la reproductibilité du prétraitement.
- effets possibles du prétraitement sur les populations rares.

2. Clustering classique

- PCA + K-Means, PCA + Leiden ;
- avantages : simples, rapides, interprétables ;
- limites : sensibilité au bruit et aux populations rares.

3. Approches par deep learning

- autoencodeurs, scDeepCluster, scMAE, scNAME, (scCDG, scVI-DCT) ?? ;
- intérêt : apprendre un espace latent plus adapté au clustering ;
- limites : coût, hyperparamètres, reproductibilité, généralisation.

4. Détection des populations rares

- La détection des classes rares est une problématique à laquelle des algorithmes ont tenté de répondre (Giniclust ? CellSIUS ?)

- expliquer pourquoi les classes rares contribuent peu à une loss moyenne ;
- introduire l'idée de pondération, de régularisation ou de post-traitement ;

5. Effets de batch et généralisation

- présenter le problème des variations techniques entre batch ;
- expliquer pourquoi un bon clustering transductif ne garantit pas une bonne prédiction sur de nouvelles cellules ;
- introduire l'intérêt d'une évaluation inductive.

6. Benchmarking des algorithmes

- besoin d'une comparaison standardisée ;
- choix des métriques : ARI, NMI, ACC, métriques rares, batch metrics ;
- distinction entre protocole transductif et protocole inductif.
- importance du même prétraitement, des mêmes seeds et des mêmes exports pour comparer.

7. Place de scRAW

- motivation : rendre les cellules rares plus visibles pendant l'apprentissage ;
- positionnement : apprentissage spécifique et dirigé vers les populations rares et l'effet batch.

Figure ou tableau utile

- Tableau comparatif des algorithmes de l'état de l'art testés dans SCRBenchmark.
- Schéma simple : données scRNA-seq vers prétraitement, embedding, clustering, métriques.
- Figure conceptuelle montrant pourquoi les populations rares sont absorbées par les classes majoritaires.

0.3 Matériel et méthodes

Objectif de la section

Dire précisément ce qui a été construit et comment les expériences ont été menées.

0.3.1 Données et environnement expérimental

- Présenter les jeux de données utilisés : nom, espèce, tissu, nombre de cellules, nombre de batch.
- Mentionner l'environnement logiciel : Python, PyTorch, Scanpy, AnnData, Streamlit, GPU, SSH.
- Préciser les formats d'entrée et de sortie : `.h5ad`.
- Ajouter un tableau des datasets avec taille, nombre de classes, classes rares et protocole utilisé.

0.3.2 Logiciel interactif de benchmarking

- Expliquer l'objectif de SCRBenchmark : centraliser chargement des données, sélection des algorithmes, exécution, visualisation, export.
- Décrire les deux modes : interface interactive et ligne de commande.
- Décrire la structure logique : registre d'algorithmes, gestion des données, métriques, visualisations.
- Expliquer pourquoi cet outil était nécessaire avant d'interpréter les résultats.
- Décrire les sorties sauvegardées : résultats bruts, tableaux agrégés, figures, configurations.

0.3.3 Algorithmes de l'état de l'art testés

- Lister les algorithmes retenus et justifier leur présence.
- Séparer les baselines simples, les méthodes deep learning et les méthodes avec correction de batch.
- Préciser les paramètres communs et les conditions de comparaison.

0.3.4 Description de scRAW

- Présenter le pipeline : prétraitement, autoencodeur, espace latent, pondération dynamique, DANN, Triplet Loss, clustering final.
- Expliquer la logique de pondération des cellules rares : cellules de petits pseudo-clusters ou zones peu denses ont plus de poids.
- Décrire les variantes testées.
- Expliquer les sorties produites par scRAW : embeddings, labels, poids cellulaires, modèle, figures.
- Distinguer la version stable, la version inductive et optimisée ?
- Ajouter un schéma du pipeline complet : données vers prétraitement, autoencodeur, pondération, clustering, métriques.

0.3.5 Recherche d'hyperparamètres

- Décrire ce qui a été exploré : architecture, dimension latente, epochs, pondération, clustering, pertes, prétraitement latent.
- Préciser la stratégie
- Expliquer que l'objectif n'est pas seulement le meilleur score global, mais le compromis global/rare.
- Mentionner les seeds, la répétabilité et la variabilité des résultats.
- Distinguer recherche large, ablations ciblées et consolidation finale.
- Décrire les critères d'arrêt ou de sélection des configurations.

0.3.6 Tests pour rendre scRAW inductif

- Distinguer transductif et inductif.
- Expliquer le protocole : train sur certains batch, gel du prétraitement et du modèle, prédiction sur batch non vus.
- Décrire les artefacts sauvegardés : modèle, état de prétraitement, référence centroïdes, configuration.
- Expliquer pourquoi l'inductif est plus proche d'un usage réel : nouvelles cellules, nouveau batch, réanalyse rapide.
- Présenter les limites possibles : batch non représentatif, classes absentes du train.

0.3.7 Métriques et analyses

- Expliquer les métriques globales : ARI, NMI, ACC.
- Expliquer les métriques centrées rares : RareACC, UltraRareACC et erreur par type cellulaire si présentées.
- Expliquer les métriques qualitatives : UMAP, matrices de confusion, visualisation des poids cellulaires.
- Discuter pourquoi une seule métrique peut être trompeuse.
- Mentionner le traitement des clusters bruit/outliers par HDBSCAN.

0.3.8 Reproductibilité et traçabilité

- Sauvegarde des configurations exactes.
- Conservation des logs et des tableaux de résultats.
- Export des embeddings, labels prédits, poids et figures.
- Gestion des seeds et de l'environnement logiciel.

0.4 Résultats et discussion

Objectif de la section

Raconter les résultats comme une progression : l'outil permet de comparer, la comparaison révèle des limites, scRAW répond à ces limites, puis l'optimisation et l'inductif testent sa solidité.

0.4.1 Résultat 1 : logiciel de benchmarking

- Montrer ce que le logiciel permet de faire.
- Inclure schéma d'architecture.
- Discuter l'apport : facilité pour les biologistes non info, reproductibilité, comparaison, visualisation.

0.4.2 Résultat 2 : comparaison des algorithmes existants

- Présenter un tableau global des scores.
- Identifier les forces/faiblesses des familles d’algorithmes.
- Mettre en avant les limites observées sur populations rares.
- Comparer les performances globales et les performances sur classes rares.
- Montrer les temps de calcul et la stabilité.

0.4.3 Résultat 3 : performances et comportement de scRAW

- Montrer les scores principaux de scRAW par rapport aux autres meilleurs algorithmes.
- Discuter les gains, mais aussi les compromis.
- Montrer les UMAPs et UMAPs des poids (figures JOBIM?).

0.4.4 Résultat 4 : recherche d’hyperparamètres

- Présenter les campagnes importantes.
- Montrer ce qui a été validé, invalidé ou jugé instable.
- Faire ressortir le compromis entre score global et détection des rares ?
- Discuter les configurations qui échouent.
- Montrer les effets du clustering final, de la loss, des poids. (afficher le plot Optuna?)

0.4.5 Résultat 5 : premiers tests inductifs

- Présenter le protocole train/test par batch.
- Montrer les résultats
- Discuter ce que ces tests disent de la généralisation de scRAW.
- Comparer l’inductif à une analyse transductive lorsque c’est possible.

0.4.6 Résultat 6 : analyse qualitative des clusters

- Inclure UMAP, matrices de confusion ou erreurs par type cellulaire.
- Identifier les types cellulaires bien retrouvés et ceux qui restent difficiles. Se baser sur les marqueurs génétiques aussi (voir ce qu’on fait ssCluBench pour l’analyse biologique)
- Discuter les clusters bruit ou non assignés.

0.4.7 Résultat 7 : coût de calcul et difficultés rencontrées

- Comparer qualitativement les méthodes rapides, lourdes, stables ou difficiles à installer (difficulté rencontré de version TensorFlow/pytorch par exemple).
- Mentionner le gain attendu du mode inductif pour réutiliser un modèle sans tout réentraîner.

0.4.8 Discussion générale

- Ce qui fonctionne bien.
- Ce qui reste fragile.
- Limites : temps de calcul, sensibilité aux hyperparamètres, taille des datasets, validation biologique, origine de la vérité terrain.
- Discuter le compromis entre maximisation du score global et conservation des petites populations.
- Mentionner les risques de sur-optimisation sur un dataset de référence.

0.5 Conclusion et perspectives

Points à traiter

- Contribution logicielle : SCRBenchmark.
- Contribution méthodologique : comparaison standardisée des algorithmes.
- Contribution algorithmique : scRAW, loss pondérée.
- Contribution expérimentale : recherche d'hyperparamètres et tests inductifs.
- Perspectives : à définir. (valider les populations rares avec des marqueurs ou une expertise externe ?)

0.6 Figures et tableaux à préparer

- **Schéma général du pipeline de benchmarking** : données scRNA-seq, prétraitement, algorithmes, clustering, métriques et exports.
- **Capture ou schéma de SCRBenchmark** : montrer l'interface, les modes d'utilisation et les sorties produites.
- **Tableau des jeux de données** : nom, espèce, tissu, nombre de cellules, nombre de gènes, nombre de classes, classes rares et batches.
- **Tableau des algorithmes testés** : famille de méthode, objectif, type d'entrée, prise en compte du batch, paramètres principaux et statut dans le benchmark.
- **Tableau des métriques** : Définir quelles métriques seront utilisées.
- **Schéma du pipeline scRAW** : prétraitement, autoencodeur, espace latent, pondération rare-aware, pertes utilisées, clustering final et exports.
- **Figure conceptuelle sur les populations rares** : illustrer pourquoi une petite population peut être absorbée par des classes majoritaires.
- **Tableau principal des performances** : comparaison des algorithmes sur les métriques choisies
- **UMAP comparatifs** : vérité terrain, meilleurs algorithmes de l'état de l'art et scRAW sur les datasets choisis.

- **Matrices de confusion** : montrer les populations bien retrouvées, les confusions entre types proches et les classes rares perdues.
- **Visualisation des poids cellulaires de scRAW** : UMAP coloré par poids o pour vérifier que les zones minoritaires sont mises en avant.
- **Tableau d’ablation** : Idem que Jobim.
- **Figure de recherche d’hyperparamètres** : résumé Optuna ou graphiques montrant les compromis entre performance globale, performance rare et stabilité.
- **Figure inductive** : schéma train/test par batch, puis comparaison entre résultats transductifs et inductifs et montrer que scRAW est meilleur.
- **Tableau du coût de calcul** : performance en fonction du temps d’exécution
- **Figure ou tableau d’analyse biologique** : À définir ce qu’on peut faire.

Bibliographie

- [1] Fabien BIDEET et al. « scRAW : Representation learning for rare cell population identification ». In : ().
- [2] Ricardo J. G. B. CAMPELLO, Davoud MOULAVI et Jörg SANDER. « Hierarchical Density Estimates for Data Clustering, Visualization, and Outlier Detection ». In : *ACM Transactions on Knowledge Discovery from Data* 10.1 (2015), p. 1-51. DOI : [10.1145/2733381](https://doi.org/10.1145/2733381).
- [3] Mathilde CARON et al. *Deep Clustering for Unsupervised Learning of Visual Features*. 18 mars 2019. DOI : [10.48550/arXiv.1807.05520](https://doi.org/10.48550/arXiv.1807.05520). arXiv : [1807.05520\[cs\]](https://arxiv.org/abs/1807.05520). URL : <http://arxiv.org/abs/1807.05520> (visité le 17/03/2026).
- [4] Zhaoyu FANG, Ruiqing ZHENG et Min LI. « scMAE : a masked autoencoder for single-cell RNA-seq clustering ». In : *Bioinformatics* 40.1 (2024), btac020. DOI : [10.1093/bioinformatics/btac020](https://doi.org/10.1093/bioinformatics/btac020).
- [5] Zhaoyu FANG, Ruiqing ZHENG et Min LI. « scMAE : a masked autoencoder for single-cell RNA-seq clustering ». In : *Bioinformatics* 40.1 (2 jan. 2024). Sous la dir. d'Anthony MATHÉLIER, btac020. ISSN : 1367-4811. DOI : [10.1093/bioinformatics/btac020](https://doi.org/10.1093/bioinformatics/btac020). URL : <https://academic.oup.com/bioinformatics/article/doi/10.1093/bioinformatics/btac020/7564641> (visité le 17/03/2026).
- [6] Fatemeh S Hashemi GOLPAYEGANI et al. « INTERPRETABLE SELF-SUPERVISED PROTOTYPE LEARNING FOR SINGLE-CELL TRANSCRIPTOMICS ». In : (2025).
- [7] Diederik P. KINGMA et Jimmy BA. « Adam : A Method for Stochastic Optimization ». In : *arXiv preprint arXiv :1412.6980* (2014).
- [8] De-Min LIANG et Pu-Feng DU. « scMUG : deep clustering analysis of single-cell RNA-seq data on multiple gene functional modules ». In : *Briefings in Bioinformatics* 26.2 (4 mars 2025), bbaf138. ISSN : 1467-5463, 1477-4054. DOI : [10.1093/bib/bbaf138](https://doi.org/10.1093/bib/bbaf138). URL : <https://academic.oup.com/bib/article/doi/10.1093/bib/bbaf138/8106809> (visité le 27/03/2026).
- [9] Romain LOPEZ et al. « Deep generative modeling for single-cell transcriptomics ». In : *Nature Methods* 15.12 (2018), p. 1053-1058. DOI : [10.1038/s41592-018-0229-2](https://doi.org/10.1038/s41592-018-0229-2).
- [10] Malte D. LUECKEN et al. « Benchmarking atlas-level data integration in single-cell genomics ». In : *Nature Methods* 19.1 (jan. 2022), p. 41-50. ISSN : 1548-7105. DOI : [10.1038/s41592-021-01336-8](https://doi.org/10.1038/s41592-021-01336-8). URL : <https://www.nature.com/articles/s41592-021-01336-8> (visité le 22/04/2026).

- [11] Hua MENG, Chuan QIN et Zhiguo LONG. « scHNTL : single-cell RNA-seq data clustering augmented by high-order neighbors and triplet loss ». In : *Bioinformatics* 41.2 (4 fév. 2025). Sous la dir. de Laura CANTINI, btaf044. ISSN : 1367-4811. DOI : [10.1093/bioinformatics/btaf044](https://doi.org/10.1093/bioinformatics/btaf044). URL : <https://academic.oup.com/bioinformatics/article/doi/10.1093/bioinformatics/btaf044/7989292> (visité le 27/03/2026).
- [12] Vincent A. TRAAG, Ludo WALTMAN et Nees Jan van ECK. « From Louvain to Leiden : guaranteeing well-connected communities ». In : *Scientific Reports* 9.1 (2019), p. 5233. DOI : [10.1038/s41598-019-41695-z](https://doi.org/10.1038/s41598-019-41695-z).
- [13] Isaac VIRSHUP et al. « The AnnData object in single-cell omics ». In : *Genome Biology* (2021). Reference for the AnnData data structure.
- [14] Hui WAN, Liang CHEN et Minghua DENG. « scNAME : neighborhood contrastive clustering with ancillary mask estimation for scRNA-seq data ». In : *Bioinformatics* 38.6 (4 mars 2022). Sous la dir. de Christina KENDZIORSKI, p. 1575-1583. ISSN : 1367-4803, 1367-4811. DOI : [10.1093/bioinformatics/btac011](https://doi.org/10.1093/bioinformatics/btac011). URL : <https://academic.oup.com/bioinformatics/article/38/6/1575/6499267> (visité le 27/03/2026).
- [15] C. WANG, Z. CHEN et R. XI. « Feature screening for clustering analysis ». In : *arXiv preprint arXiv :2306.12671* (2023). URL : <https://arxiv.org/abs/2306.12671>.
- [16] Jing WANG et al. « scSCCNIA : similarity matrix based contrastive clustering with neighbor information aggregation for single-cell RNA sequencing data ». In : *Briefings in Bioinformatics* 27.2 (1^{er} mars 2026), bbag094. ISSN : 1467-5463, 1477-4054. DOI : [10.1093/bib/bbag094](https://doi.org/10.1093/bib/bbag094). URL : <https://academic.oup.com/bib/article/doi/10.1093/bib/bbag094/8507273> (visité le 27/03/2026).
- [17] F. Alexander WOLF, Philip ANGERER et Fabian J. THEIS. « Scanpy : large-scale single-cell gene expression data analysis ». In : *Genome Biology* 19.1 (2018), p. 15. DOI : [10.1186/s13059-017-1382-0](https://doi.org/10.1186/s13059-017-1382-0).
- [18] Ping XU et al. *scCDCG : Efficient Deep Structural Clustering for single-cell RNA-seq via Deep Cut-informed Graph Embedding*. 30 sept. 2025. DOI : [10.48550/arXiv.2404.06167](https://doi.org/10.48550/arXiv.2404.06167). arXiv : [2404.06167\[cs\]](https://arxiv.org/abs/2404.06167). URL : <http://arxiv.org/abs/2404.06167> (visité le 27/03/2026).
- [19] Chenxin YI et al. « Benchmarking deep learning methods for biologically conserved single-cell integration ». In : *Genome Biology* 26.1 (20 nov. 2025), p. 398. ISSN : 1474-760X. DOI : [10.1186/s13059-025-03869-z](https://doi.org/10.1186/s13059-025-03869-z). URL : <https://doi.org/10.1186/s13059-025-03869-z> (visité le 14/04/2026).