



Université de Bordeaux
Master Bio-informatique, 2^e année

Plan détaillé du rapport de stage

Benchmarking interactif, développement de scRAW et évaluation inductive pour le clustering scRNA-seq

Fabien Bidet

Avril 2026

Période : Janvier-Juin 2026

Structure d'accueil : LaBRI

Encadrant universitaire : Victoria Bourgeais, Loann Giovannangeli, Patricia Thébault

Tuteur de stage : Adélaïde Raguin

Table des matières

0.1	Introduction	2
0.1.1	Environnement de travail	2
0.1.2	Introduction du sujet de stage	3
0.2	État de l’art	5
0.2.1	Données	5
0.2.2	Traitements de données	6
0.2.3	Algorithmes de clustering	7
0.3	Comparaison de l’existant	10
0.3.1	Logiciel	10
0.3.2	Expériences	10
0.4	scRAW	11
0.4.1	Positionnement et motivation	11
0.4.2	Pipeline	12
0.4.3	Fonctions de perte et variantes	12
0.4.4	Recherche d’hyperparamètres	12
0.4.5	Résultats et discussion	12
0.5	Travaux complémentaires	13
0.5.1	Transfert de loss	13
0.5.2	Induction	13
0.5.3	Interprétation biologique	14
0.6	Conclusion	14

0.1 Introduction

0.1.1 Environnement de travail

Ce stage de fin d'études s'est déroulé du 4 janvier au 30 juin 2026 au sein du Laboratoire Bordelais de Recherche en Informatique (LaBRI). J'ai intégré l'équipe Bench to Knowledge and Beyond (BKB), dirigée par Romain Bourqui (responsable d'équipe) et Patricia Thébault (adjointe). Cette équipe est rattachée au département Systèmes et Données (SeD). Afin de mieux appréhender la structure dans laquelle j'ai évolué, l'organisation du laboratoire est détaillée ci-après.

Organisation du laboratoire

Le LaBRI est structuré autour de plusieurs grands pôles :

- **Direction** : Pascal Desbarats (Directeur par intérim), Nicolas Hanusse (Directeur adjoint par intérim), Serge Chaumette (Chargé de mission transfert et valorisation).
- **Administration** (Administratrice d'unité : Christine Richard) :
 - *Équipe administrative* (resp. Cathy Roubineau) : Accueil (Claire Douvier, Laurence Pinosa), Assistante administrative (Safia Amsili), Assistante de communication (Auriane Dantès).
 - *Équipe financière* (resp. Chloé Godard) : Gestionnaires (Isabelle Garcia, Anthony Gau, Emmanuelle Lesage, Elia Meyre).
 - *Assistante du SCRIME* : Annick Mersier.
- **Recherche** (structurée en plusieurs départements) :
 - *Image et Son* (Fabien Baldacci)
 - *Combinatoire et Algorithmique* (Cyril Gavaille)
 - *Systèmes et Données* (Jean-Rémy Falleri), département auquel appartient l'équipe BKB.
 - *Méthodes et Modèles formels* (Laurent Bienvenu)
 - *Supports et AlgoriThmes pour les Applications Numériques hAutres performances* (Pierre Ramet)
- **Appui à la recherche** :
 - *Ingénieurs affectés sur projet* : Nathalie Furmento, Frédéric Lalanne, Boris Mansencal, Gérald Point.
 - *Équipe soutien "Systèmes - Réseaux"* (resp. Pascal Ung) : Ingénieurs ASR (Michaël Fontaine, Emmanuel Fontaine, Gabriel Larrouy), Technicien ASR (Alexandre Issouli), Ingénieur DEV-Web (Pierre Lacroix).
- **Autre** : Assistant de prévention (Gérald Point).

Équipe d'encadrement

Au cours de ce stage, j'ai été encadré par une équipe aux expertises complémentaires :

- **Victoria Bourgeais**, enseignante-chercheuse experte dans l'application de l'apprentissage profond au domaine de la santé ;
- **Loann Giovannangeli**, enseignant-chercheur en visualisation de l'information et intelligence artificielle ;
- **Patricia Thébault**, enseignante-chercheuse en sciences des données omiques et réseaux biologiques.

Cadre de travail

J'ai effectué mes travaux dans un bureau partagé avec des doctorants et d'autres stagiaires. Ce contexte s'est révélé particulièrement enrichissant, facilitant les échanges de connaissances au quotidien et me permettant de mieux cerner les enjeux d'une thèse et de la vie de jeune chercheur(se).

Par ailleurs, j'ai pu assister aux séminaires hebdomadaires organisés par les doctorants de l'équipe BKB, durant lesquels des chercheurs invités présentaient leurs travaux en bioinformatique. J'ai également eu l'opportunité de participer aux séminaires d'autres équipes, notamment celles spécialisées en intelligence artificielle. Ces événements ont constitué une source d'apprentissage scientifique de pointe, idéale pour mon profil situé à l'interface entre la bioinformatique et l'intelligence artificielle. D'un point de vue technique, j'ai bénéficié d'un accès distant (via SSH) à un serveur de calcul interne au LaBRI pour réaliser mes expérimentations.

Suivi et méthodologie

L'avancement de mes travaux a été rythmé par des réunions régulières. Plusieurs réunions mensuelles étaient organisées avec mes encadrants pour faire le point sur l'avancement scientifique. De plus, des réunions bimensuelles ont été planifiées avec Elodie Darbot et Cyril Dourthe afin de croiser nos approches et de discuter de nos problématiques communes. Enfin, j'ai pu compter sur la grande disponibilité de ma tutrice de stage pour faire le point sur mon avancement et répondre à mes interrogations tout au long de cette période.

0.1.2 Introduction du sujet de stage

Le séquençage de l'ARN à l'échelle de la cellule unique (*single-cell RNA sequencing*, scRNA-seq) a profondément transformé l'analyse des tissus biologiques. Contrairement aux approches transcriptomiques classiques, qui mesurent une expression moyenne sur un ensemble de cellules, le scRNA-seq permet d'observer les profils d'expression cellule par cellule. Il devient alors possible d'étudier l'hétérogénéité interne d'un tissu, d'identifier différents types ou états cellulaires, et de mettre en évidence des populations minoritaires qui auraient été masquées dans une mesure globale.

Cette richesse d'information s'accompagne cependant de difficultés importantes. Les données scRNA-seq sont de très grande dimension, car chaque cellule est décrite par l'expression de

plusieurs milliers de gènes. Elles sont également bruitées, très creuses, sensibles aux événements de non-détection et souvent affectées par des effets de batch liés au protocole expérimental, au laboratoire ou à la plateforme de séquençage [17]. Avant toute interprétation biologique, il est donc nécessaire de construire une représentation plus compacte et plus robuste des cellules.

Dans ce contexte, le clustering constitue une étape centrale des analyses scRNA-seq. Il consiste à regrouper les cellules présentant des profils d'expression similaires afin de retrouver des types cellulaires, des sous-types ou des états fonctionnels. Des pipelines classiques, comme ceux fondés sur une réduction de dimension suivie d'un clustering, sont aujourd'hui largement utilisés dans les outils bioinformatiques standards [29]. Plus récemment, les méthodes d'apprentissage profond ont cherché à apprendre des espaces latents plus adaptés à la complexité des données, notamment à l'aide d'autoencodeurs ou de modèles probabilistes [16].

La difficulté étudiée pendant ce stage concerne plus spécifiquement les populations cellulaires rares. En biologie, ces populations peuvent correspondre à des cellules immunitaires minoritaires, à un sous-type tumoral, à une population pathologique, à un état transitoire de différenciation ou encore à des cellules spécifiques d'un tissu. Leur faible proportion ne signifie donc pas qu'elles sont secondaires : au contraire, elles peuvent porter un signal biologique essentiel. Pourtant, du point de vue algorithmique, elles sont particulièrement fragiles. Comme elles représentent peu d'observations, elles contribuent faiblement à l'apprentissage des modèles et peuvent facilement être absorbées et confondues par une population majoritaire ou par un type cellulaire proche. Un bon score moyen dans une métrique généraliste peut alors masquer un échec important : la disparition d'une population biologiquement pertinente.

L'enjeu de ce mémoire est donc de dépasser une évaluation uniquement globale du clustering. Une méthode utile en pratique doit non seulement produire une partition cohérente de l'ensemble des cellules, mais aussi préserver les populations minoritaires, rester traçable dans un protocole expérimental reproductible, et pouvoir être utilisée sur de nouvelles observations. Ce dernier point est particulièrement important : dans un contexte réel, un modèle n'est pas toujours réentraîné depuis zéro à chaque arrivée de données. Il doit pouvoir projeter ou classer de nouvelles cellules, issues par exemple d'un nouveau patient, d'un nouveau batch ou d'une expérience complémentaire. Cette capacité correspond à un usage inductif, plus proche des besoins d'analyse bioinformatique appliquée.

Mon stage s'est inscrit dans cette problématique à l'interface entre bioinformatique, apprentissage automatique et évaluation expérimentale. Le travail réalisé s'est articulé autour de quatre contributions principales. La première a consisté à développer et structurer **SCRBenchmark**, une interface web interactive destinée à comparer différentes méthodes de clustering scRNA-seq sur plusieurs jeux de données. La deuxième a porté sur la comparaison de méthodes existantes, classiques et fondées sur l'apprentissage profond, en intégrant des métriques globales mais aussi des métriques centrées sur les classes rares. La troisième contribution a été le développement de **scRAW**, une méthode visant à apprendre une représentation latente en donnant davantage d'importance aux cellules rares ou peu denses pendant l'apprentissage. Enfin, des travaux complémentaires ont exploré le transfert de cette logique de pondération vers d'autres pertes et les premiers tests d'un comportement inductif.

La question directrice du mémoire peut ainsi se formuler de la manière suivante : comment

construire, évaluer et améliorer un pipeline de clustering scRNA-seq capable de mieux préserver les populations cellulaires rares, tout en restant reproductible et utilisable sur de nouvelles données? Pour y répondre, la suite du rapport présente d'abord les notions nécessaires à la compréhension des données scRNA-seq et des méthodes de clustering. Elle décrit ensuite le protocole de comparaison mis en place, puis détaille la conception et l'évaluation de scRAW. Enfin, elle discute les extensions explorées pendant le stage, notamment le transfert de loss, l'induction et les pistes d'interprétation biologique.

0.2 État de l'art

L'objectif de cette section est de présenter les bases nécessaires à la compréhension du rapport pour mieux comprendre mes contributions et où elles se situent par rapport à la recherche actuelle. Nous commencerons par examiner les jeux de données utilisés, puis nous verrons comment ces données sont préparées. Enfin, nous ferons une présentation des algorithmes de clustering existants, en comprenant notamment pourquoi les modèles d'intelligence artificielle actuels ont souvent du mal à repérer les cellules rares.

0.2.1 Données

Pour qu'une méthode de clustering soit considérée comme fiable, elle doit faire ses preuves sur des données variées. Dans le cadre de ce stage, nous nous sommes appuyés sur une collection de jeux de données diversifiés (détaillés dans nos tables de référence).

Ces données proviennent de différents organes et espèces : pancréas humain et de souris, cerveau (Zeisel), rate (spleen), sang (PBMC), testicules, foie, ou encore rétine de macaque. Chaque jeu de données possède ses propres défis :

- **La taille** : Cela va de petits jeux de données d'environ 2 000 cellules (comme *Paul15 bone marrow* ou certains sous-jeux du pancréas) jusqu'à de très gros ensembles dépassant les 30 000 cellules (comme la rétine de macaque ou les PBMC).
- **Les effets de batch** : La plupart des jeux de données sont composés de plusieurs "batches" (lots expérimentaux). Par exemple, les données de PBMC combinent 16 lots différents, et la rétine de macaque en compte 30.
- **Les populations rares** : C'est le cœur de notre problématique. Presque tous nos jeux de données contiennent des types cellulaires dits "rares" (représentant moins de 5 % des cellules) ou "ultra-rares" (moins de 1 %). Par exemple, dans les données du pancréas humain de Baron, certaines cellules immunitaires ou cellules de Schwann ne représentent qu'une fraction de pourcent du total.

L'utilisation d'annotations pré-existantes (la "vérité terrain") nous permet d'évaluer objectivement si les algorithmes parviennent à retrouver ces populations ou s'ils les noient dans la masse.

Nom du Dataset	Cellules	Gènes	Batches	Classes Rares (< 5%)
BBAG094 Zeisel	3 006	19 972	10	4
BBAG094 spleen	9 552	23 341	2	3
Baron human pancreas	8 569	20 125	4	9
Human testis GSE112013	6 490	27 477	6	4
Kang PBMC	24 679	35 635	16	1
Macaque retina bipolar	30 302	36 162	30	4
Pancreas raw counts	16 400	14 813	8	9
Pancreas 4 batches	6 339	14 813	4	7
Paul15 bone marrow	2 730	3 451	1	9
SCIB Human Pancreas 1	1 937	20 125	1	8
SCIB Human Pancreas 2	1 724	20 125	1	10
SCIB Mouse Pancreas 1	822	14 878	1	9
Tabula Muris liver	2 859	22 966	1	5

TABLE 1 – Récapitulatif des jeux de données utilisés pour l'évaluation.

0.2.2 Traitements de données

Les données brutes issues du séquençage scRNA-seq sont extrêmement bruitées et pleines de zéros (des gènes non détectés). Il est donc indispensable de les nettoyer et de les préparer.

Pré-process (Le nettoyage initial)

Le traitement standard [17] consiste d'abord à filtrer les cellules de mauvaise qualité et les gènes très peu exprimés. Ensuite, on normalise les données pour que toutes les cellules soient comparables, puis on applique une transformation mathématique (le logarithme) pour atténuer les écarts extrêmes. Enfin, on ne conserve généralement que les gènes dits "hautement variables" (HVG), c'est-à-dire ceux qui différencient le mieux les cellules entre elles. Bien que ces étapes soient standardisées, elles présentent un risque pour les cellules rares : un filtrage trop agressif peut effacer les quelques gènes qui caractérisaient spécifiquement une toute petite population.

Batch effect (L'effet de lot)

L'effet de batch est un biais technique. Si l'on séquence le même tissu dans deux laboratoires différents, ou sur deux machines différentes, les cellules auront tendance à se regrouper par "laboratoire" plutôt que par "type cellulaire". Il existe des méthodes dédiées pour corriger ce problème (comme ComBat [10], Harmony [12], Scanorama [8], ou scVI [16]). L'objectif est d'aligner les différents lots pour effacer la signature technique. Cependant, la difficulté est de ne pas "sur-corriger" : en voulant effacer les différences techniques, on risque de gommer de vraies différences biologiques, en particulier celles des populations rares qui pourraient n'apparaître que dans un seul lot. De plus, il est crucial de réfléchir à la manière d'appliquer ces corrections sur de nouvelles données (mode inductif) sans avoir à tout recalculer depuis le début.

Outil	Méthodologie	Principe de correction
ComBat [10]	Modèle bayésien empirique	Ajustement des moyennes et variances des gènes par lot
Harmony [12]	Soft K-Means itératif	Alignement des cellules similaires de lots différents en PCA
Scanorama [8]	Mutual Nearest Neighbors (MNN)	Identification des cellules "panoramas" communes entre les lots
scVI [16]	Autoencodeur Variationnel (VAE)	Modélisation probabiliste du bruit et des batchs dans l'espace latent

TABLE 2 – Principaux outils de correction de l'effet de lot (Batch Effect).

0.2.3 Algorithmes de clustering

Une fois les données prêtes, l'objectif est de regrouper les cellules similaires.

Approches classiques

L'approche la plus courante en bioinformatique consiste à simplifier les données (généralement via une méthode appelée PCA), puis à regrouper directement les cellules avec un algorithme comme K-Means [19], ou bien à construire un graphe où chaque cellule est reliée à ses voisines les plus proches pour y identifier des communautés avec des algorithmes comme Louvain [2] ou Leiden [24]. Ces méthodes sont très rapides, faciles à utiliser et intégrées dans des outils standards comme Scanpy [29]. Toutefois, elles sont très sensibles au nettoyage initial des données. De plus, si une population est très petite, elle risque de ne pas former sa propre communauté dans le graphe et d'être absorbée par une population voisine plus grande.

Approches Deep Learning (Apprentissage Profond)

Pour aller plus loin, les méthodes basées sur le Deep Learning (l'intelligence artificielle) apprennent à représenter les cellules dans un nouvel espace mathématique (l'espace latent) de manière beaucoup plus complexe et performante que la PCA. Ces méthodes, souvent basées sur des autoencodeurs, s'entraînent en essayant de minimiser une "fonction de perte" (ou *loss*). Cette *loss* est une note qui sanctionne le modèle lorsqu'il se trompe.

Pour bien comprendre, regardons sur quoi se base la perte totale (*total loss*) de différents modèles de l'état de l'art :

- **La perte de reconstruction** : Des modèles comme scVI [16] ou scMAE [5] cherchent avant tout à bien reconstruire le profil d'expression initial de la cellule. Si le modèle compresse mal l'information et n'arrive pas à deviner les gènes de départ, sa perte augmente.
- **La perte de clustering** : Des méthodes comme DESC [13], scDeepCluster [23] ou scNAME [26] ajoutent une contrainte supplémentaire. Elles mesurent les distances entre les cellules

et forcent le modèle à regrouper les cellules qui se ressemblent de plus en plus au fil du temps (souvent en minimisant une mesure de différence appelée divergence KL).

Le cœur du problème avec les populations rares vient précisément de la manière dont cette perte totale est calculée. Le modèle cherche à minimiser cette perte globale sur l'ensemble des données. Les populations majoritaires (qui contiennent des milliers de cellules) vont avoir un poids énorme dans ce calcul. À l'inverse, si le modèle se trompe sur un type cellulaire rare (qui ne contient que quelques dizaines de cellules), cela fera à peine bouger la perte globale. Le réseau de neurones va donc avoir tendance à "sacrifier" la précision sur les cellules rares pour optimiser sa représentation mathématique globale.

Pour résumer, le tableau 3 dresse un panorama pédagogique des méthodes abordées, des approches classiques (reposant sur des heuristiques géométriques ou de graphe) jusqu'aux architectures Deep Learning (pilotées par des fonctions de perte complexes).

Algorithme	Catégorie	Principe fondamental	Objectif d'optimisation (Critère / Loss)
Méthodes Classiques			
PCA	Réduction	Combinaison linéaire des gènes	Maximisation de la variance expliquée
K-Means [19]	Clustering	Affectation itérative aux centroïdes	Minimisation de l'inertie intra-cluster
Louvain [2]	Graphe	Fusion hiérarchique de nœuds	Maximisation de la modularité
Leiden [24]	Graphe	Amélioration de Louvain	Maximisation de la modularité (sans déconnexions)
Méthodes Deep Learning			
scVI [16]	Autoencodeur (VAE)	Espace latent probabiliste	Reconstruction (ZINB/NB) + Divergence KL
scMAE [5]	Masked Autoencoder	Masquage de gènes	Reconstruction (MSE)
DESC [13]	Autoencodeur	Espace latent + Clustering itératif	Reconstruction + Clustering (KL avec cible)
scDeepCluster [23]	Autoencodeur	Modélisation du bruit scRNA-seq	Reconstruction (ZINB) + Clustering (KL)
scNAME [26]	Contrastive Learning	Rapprochement des cellules similaires	Reconstruction + Clustering + Contrastive
scCDCG [30]	Graph Embedding	Plongement structural du graphe	Reconstruction + Transport optimal + Graph Cut
Méthodes Spécifiques (Cellules Rares)			
GiniClust [9]	Statistique	Utilisation de l'indice de Gini	Identification de gènes marqueurs atypiques
CellSIUS [21]	Heuristique	Signatures transcriptomiques à la marge	Extraction de sous-types cellulaires mineurs
scCAD [31]	Autoencodeur / Graphe	Isolement des types rares	Détection d'anomalies / Décomposition

Les types cellulaires dans les algorithmes

Face à ce constat, l'identification des populations minoritaires est devenue un véritable enjeu. Des algorithmes se sont déjà concentrés sur cette question, mais en adoptant diverses stratégies. Par exemple, des outils comme **GiniClust** [9] se basent sur des indices statistiques particuliers (l'indice de Gini) pour repérer spécifiquement les gènes marqueurs de cellules rares indépendamment des clusters globaux. D'autres, comme **CellSIUS** [21], cherchent des signatures transcriptomiques uniques à la marge des gros clusters. Enfin, des méthodes plus récentes comme **scCAD** [31] ou **scAID** [15] utilisent des approches de détection d'anomalies ou de décomposition itérative de clusters pour isoler les cellules qui ont un comportement atypique par rapport à la masse globale.

Tout comme nous, ces méthodes partent du principe qu'une approche de clustering globale classique ne suffit pas pour préserver la rareté. Notre démarche (scRAW) s'inscrit dans cette lignée : nous voulons forcer le modèle d'intelligence artificielle à accorder volontairement plus d'importance mathématique aux cellules isolées lors du calcul de sa *loss*, afin de les préserver de manière robuste et naturelle dès la construction de l'espace latent.

0.3 Comparaison de l'existant

Objectif de la section

Montrer comment les méthodes existantes ont été rendues comparables : construction logicielle, protocole expérimental, métriques et premiers résultats. Cette section doit préparer la transition vers scRAW.

0.3.1 Logiciel

- Présenter SCRBenchmark comme outil de benchmarking : chargement des données, sélection des méthodes, exécution, visualisation, export des résultats.
- Décrire les deux modes d'utilisation : interface interactive et ligne de commande.
- Présenter la structure logique : registre d'algorithmes, gestion des datasets, prétraitement, métriques, visualisations, sauvegarde des configurations.
- Expliquer pourquoi cet outil était nécessaire avant d'interpréter les résultats : homogénéiser les entrées, les sorties, les métriques et les figures.
- Mentionner les sorties sauvegardées : résultats bruts, tableaux agrégés, embeddings, labels prédits, figures, configurations et logs.
- Discuter l'apport pratique : reproductibilité, traçabilité, comparaison plus simple pour des utilisateurs non spécialistes du code.

0.3.2 Expériences

Données et splits

- *Présenter les jeux de données retenus : nom, espèce, tissu, nombre de cellules, nombre de gènes, nombre de classes, classes rares, batches.*
- *Expliquer les critères de sélection : diversité des tissus, présence de populations rares, disponibilité de labels, présence ou non d'effet batch.*
- *Décrire les splits utilisés : transductif, train/test par batch, leave-one-batch-out ou autre protocole retenu.*
- *Indiquer comment les classes rares sont définies pour les métriques RareACC et UltraRareACC.*
- *Prévoir un tableau dédié aux datasets et aux splits.*

Méthodes

- *Lister les méthodes comparées : PCA + Leiden, Harmony, ComBat, Scanorama, DESC, scMAE, scNAME, scVI, scRAW et tous les algorithmes pour lesquels il y a un résultat.*
- *Préciser les paramètres harmonisés entre méthodes lorsque c'est possible : prétraitement, nombre de voisins, dimension latente, seeds, nombre de clusters ou résolution.*
- *Expliquer les contraintes pratiques : méthodes difficiles à installer, différences PyTorch/TensorFlow, temps de calcul, compatibilité GPU.*
- *Décrire les métriques : ARI, NMI, ACC, BalancedACC, RareACC, UltraRareACC, temps d'exécution et stabilité.*
- *Justifier pourquoi une seule métrique globale ne suffit pas pour juger la conservation des populations rares.*

Résultats

- *Présenter un tableau global des scores par méthode et par dataset.*
- *Identifier les familles qui fonctionnent bien globalement et celles qui préservent mieux les populations rares.*
- *Comparer performance globale et performance rare pour montrer les compromis.*
- *Montrer les UMAP comparatifs, matrices de confusion et temps de calcul lorsque les figures sont disponibles.*
- *Discuter les méthodes instables, coûteuses ou sensibles aux hyperparamètres.*
- *Conclure sur les limites observées qui motivent le développement de scRAW.*

0.4 scRAW

0.4.1 Positionnement et motivation

- *Présenter scRAW comme une réponse aux limites observées dans la comparaison de l'existant.*

- *Expliquer l'objectif : apprendre un espace latent qui conserve les structures globales tout en donnant plus d'importance aux populations rares ou peu denses.*
- *Distinguer scRAW des méthodes classiques et des autoencodeurs standards : pondération dynamique, objectif rare-aware, possibilité d'intégrer d'autres pertes.*
- *Formuler clairement l'hypothèse : si les cellules minoritaires pèsent davantage pendant l'apprentissage, elles ont plus de chances de rester séparables dans l'espace latent.*

0.4.2 Pipeline

- *Décrire les étapes : prétraitement, autoencodeur, espace latent, estimation de rareté ou de densité, pondération, pertes d'apprentissage, clustering final.*
- *Présenter les sorties : embeddings, labels prédits, poids cellulaires, modèle entraîné, figures, métriques.*
- *Expliquer le rôle de chaque bloc dans le pipeline et les paramètres importants.*
- *Prévoir un schéma complet du pipeline scRAW.*

0.4.3 Fonctions de perte et variantes

- *Décrire la loss de reconstruction pondérée et son lien avec les populations rares.*
- *Présenter les variantes testées : pondération dynamique, DANN, triplet loss, fine-tuning ou autres variantes effectivement retenues.*
- *Expliquer comment les poids cellulaires sont calculés ou mis à jour.*
- *Discuter les compromis : amélioration des rares, stabilité globale, sensibilité aux hyperparamètres.*

0.4.4 Recherche d'hyperparamètres

- *Décrire ce qui a été exploré : architecture, dimension latente, epochs, force de pondération, clustering final, pertes, prétraitement latent.*
- *Préciser la stratégie : recherche large, ablations ciblées, consolidation finale, répétitions avec plusieurs seeds si disponibles.*
- *Expliquer les critères de sélection : score global, RareACC, UltraRareACC, BalancedACC, stabilité, coût de calcul.*
- *Montrer les configurations qui améliorent les rares, celles qui échouent et celles qui créent un mauvais compromis.*
- *Prévoir une figure Optuna ou un tableau d'ablation.*

0.4.5 Résultats et discussion

- *Comparer scRAW aux meilleures méthodes de l'état de l'art sur les datasets retenus.*

- *Montrer les gains et les limites : scores, UMAP, matrices de confusion, visualisation des poids cellulaires.*
- *Discuter le comportement sur classes rares, classes fréquentes et batches difficiles.*
- *Présenter le coût de calcul et les difficultés rencontrées.*
- *Terminer par ce que scRAW valide et ce qui reste fragile avant les extensions.*

0.5 Travaux complémentaires

Objectif de la section

Regrouper les différentes expériences complémentaires : transfert de la loss et passage à un mode inductif.

0.5.1 Transfert de loss

- *Présenter l'idée : transférer la loss de reconstruction pondérée ou la logique rare-aware vers d'autres algorithmes de deep learning.*
- *Expliquer pourquoi c'est intéressant : séparer la contribution méthodologique de scRAW de son architecture précise.*
- *Décrire le protocole expérimental : méthodes ciblées, variantes avec et sans loss transférée, datasets, métriques.*
- *Montrer les premiers résultats : gains, échecs, stabilité, coût.*
- *Discuter les limites : compatibilité des architectures, difficulté d'intégration, risque de sur-pondération des petites populations.*

0.5.2 Induction

- *Distinguer transductif et inductif : entraîner sur un ensemble de cellules puis prédire ou projeter de nouvelles cellules non vues.*
- *Décrire le protocole : train sur certains batches, gel du prétraitement et du modèle, prédiction sur batches non vus.*
- *Préciser les artefacts sauvegardés : modèle, état du prétraitement, gènes retenus, centroïdes de référence, configuration.*
- *Expliquer pourquoi l'inductif rapproche scRAW d'un usage réel : nouvelles cellules, nouveau batch, réanalyse rapide sans tout réentraîner.*
- *Présenter les résultats comparant inductif et transductif lorsque c'est possible.*
- *Discuter les limites : batch non représentatif, classes absentes du train, baisse possible des performances rares.*

0.5.3 Interprétation biologique

- *Section optionnelle selon les résultats disponibles et la place restante.*
- *Valider qualitativement certaines populations rares avec des marqueurs génétiques connus.*
- *Comparer clusters prédits, annotations et marqueurs pour éviter une interprétation uniquement métrique.*
- *Identifier les types cellulaires bien retrouvés et ceux qui restent ambigus.*
- *Mentionner qu'une validation biologique externe serait nécessaire pour confirmer certaines conclusions.*

0.6 Conclusion

- *Résumer les contributions : SCRBenchmark, comparaison standardisée, scRAW, optimisation et premières extensions.*
- *Revenir à la question directrice : comment construire, évaluer et améliorer un pipeline de clustering scRNA-seq capable de mieux préserver les populations cellulaires rares, tout en restant reproductible et utilisable sur de nouvelles données ?*
- *Présenter les limites : taille des datasets, vérité terrain, sensibilité aux hyperparamètres, coût de calcul, validation biologique.*
- *Ouvrir sur les perspectives : stabilisation de l'inductif, transfert de loss, validation par marqueurs, intégration dans un workflow utilisateur.*

Bibliographie

- [1] Fabien BIDEET et al. « scRAW : Representation learning for rare cell population identification ». In : ().
- [2] Vincent D BLONDEL et al. « Fast unfolding of communities in large networks ». In : *Journal of Statistical Mechanics : Theory and Experiment* 2008.10 (2008), P10008.
- [3] Ricardo J. G. B. CAMPELLO, Davoud MOULAVI et Jörg SANDER. « Hierarchical Density Estimates for Data Clustering, Visualization, and Outlier Detection ». In : *ACM Transactions on Knowledge Discovery from Data* 10.1 (2015), p. 1-51. DOI : [10.1145/2733381](https://doi.org/10.1145/2733381).
- [4] Mathilde CARON et al. *Deep Clustering for Unsupervised Learning of Visual Features*. 18 mars 2019. DOI : [10.48550/arXiv.1807.05520](https://doi.org/10.48550/arXiv.1807.05520). arXiv : [1807.05520\[cs\]](https://arxiv.org/abs/1807.05520). URL : <http://arxiv.org/abs/1807.05520> (visité le 17/03/2026).
- [5] Zhaoyu FANG, Ruiqing ZHENG et Min LI. « scMAE : a masked autoencoder for single-cell RNA-seq clustering ». In : *Bioinformatics* 40.1 (2024), btae020. DOI : [10.1093/bioinformatics/btae020](https://doi.org/10.1093/bioinformatics/btae020).
- [6] Zhaoyu FANG, Ruiqing ZHENG et Min LI. « scMAE : a masked autoencoder for single-cell RNA-seq clustering ». In : *Bioinformatics* 40.1 (2 jan. 2024). Sous la dir. d'Anthony MATHÉLIER, btae020. ISSN : 1367-4811. DOI : [10.1093/bioinformatics/btae020](https://doi.org/10.1093/bioinformatics/btae020). URL : <https://academic.oup.com/bioinformatics/article/doi/10.1093/bioinformatics/btae020/7564641> (visité le 17/03/2026).
- [7] Fatemeh S Hashemi GOLPAYEGANI et al. « INTERPRETABLE SELF-SUPERVISED PROTOTYPE LEARNING FOR SINGLE-CELL TRANSCRIPTOMICS ». In : (2025).
- [8] Brian HIE, Bryan D. BRYSON et Bonnie BERGER. « Efficient integration of heterogeneous single-cell transcriptomes using Scanorama ». In : *Nature Biotechnology* 37.6 (2019), p. 685-691. DOI : [10.1038/s41587-019-0113-3](https://doi.org/10.1038/s41587-019-0113-3).
- [9] Lan JIANG et al. « GiniClust : detecting rare cell types from single-cell gene expression data with Gini index ». In : *Genome Biology* 17.1 (2016), p. 144. DOI : [10.1186/s13059-016-1010-4](https://doi.org/10.1186/s13059-016-1010-4).
- [10] W Evan JOHNSON, Cheng LI et Ariel RABINOVIC. « Adjusting batch effects in microarray expression data using empirical Bayes methods ». In : *Biostatistics* 8.1 (2007), p. 118-127.
- [11] Diederik P. KINGMA et Jimmy BA. « Adam : A Method for Stochastic Optimization ». In : *arXiv preprint arXiv :1412.6980* (2014).

- [12] Ilya KORSUNSKY et al. « Fast, sensitive and accurate integration of single-cell data with Harmony ». In : *Nature methods* 16.12 (2019), p. 1289-1296.
- [13] Xiangjie LI et al. « Deep learning enables accurate clustering with batch effect removal in single-cell RNA-seq analysis ». In : *Nature Communications* 11.1 (2020), p. 2338.
- [14] De-Min LIANG et Pu-Feng DU. « scMUG : deep clustering analysis of single-cell RNA-seq data on multiple gene functional modules ». In : *Briefings in Bioinformatics* 26.2 (4 mars 2025), bbaf138. ISSN : 1467-5463, 1477-4054. DOI : [10.1093/bib/bbaf138](https://academic.oup.com/bib/article/doi/10.1093/bib/bbaf138/8106809). URL : <https://academic.oup.com/bib/article/doi/10.1093/bib/bbaf138/8106809> (visité le 27/03/2026).
- [15] J. LIU et al. « scAIDE : clustering of large-scale single-cell RNA-seq data reveals putative and rare cell types ». In : *NAR Genomics and Bioinformatics* 2.4 (2020), lqaa082. DOI : [10.1093/nargab/lqaa082](https://doi.org/10.1093/nargab/lqaa082).
- [16] Romain LOPEZ et al. « Deep generative modeling for single-cell transcriptomics ». In : *Nature Methods* 15.12 (2018), p. 1053-1058. DOI : [10.1038/s41592-018-0229-2](https://doi.org/10.1038/s41592-018-0229-2).
- [17] Malte D LUECKEN et Fabian J THEIS. « Current best practices in single-cell RNA-seq analysis : a tutorial ». In : *Molecular systems biology* 15.6 (2019), e8746.
- [18] Malte D. LUECKEN et al. « Benchmarking atlas-level data integration in single-cell genomics ». In : *Nature Methods* 19.1 (jan. 2022), p. 41-50. ISSN : 1548-7105. DOI : [10.1038/s41592-021-01336-8](https://doi.org/10.1038/s41592-021-01336-8). URL : <https://www.nature.com/articles/s41592-021-01336-8> (visité le 22/04/2026).
- [19] James MACQUEEN. « Some methods for classification and analysis of multivariate observations ». In : *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*. T. 1. 14. Oakland, CA, USA. 1967, p. 281-297.
- [20] Hua MENG, Chuan QIN et Zhiguo LONG. « scHNTL : single-cell RNA-seq data clustering augmented by high-order neighbors and triplet loss ». In : *Bioinformatics* 41.2 (4 fév. 2025). Sous la dir. de Laura CANTINI, btaf044. ISSN : 1367-4811. DOI : [10.1093/bioinformatics/btaf044](https://doi.org/10.1093/bioinformatics/btaf044). URL : <https://academic.oup.com/bioinformatics/article/doi/10.1093/bioinformatics/btaf044/7989292> (visité le 27/03/2026).
- [21] Marilisa NERI et al. « CellSIUS provides sensitive and specific detection of rare cell populations from complex single cell RNA-seq data ». In : *Genome Biology* 20.142 (2019). DOI : [10.1186/s13059-019-1748-0](https://doi.org/10.1186/s13059-019-1748-0).
- [22] Yushan QIU et al. « scTPC : a novel semisupervised deep clustering model for scRNA-seq data ». In : *Bioinformatics* 40.5 (avr. 2024). ISSN : 1367-4811. DOI : [10.1093/bioinformatics/btae293](https://doi.org/10.1093/bioinformatics/btae293). URL : <http://dx.doi.org/10.1093/bioinformatics/btae293>.
- [23] Tian TIAN et al. « Clustering single-cell RNA-seq data with a model-based deep learning approach ». In : *Nature Machine Intelligence* 1.4 (2019), p. 191-198.
- [24] Vincent A. TRAAG, Ludo WALTMAN et Nees Jan van ECK. « From Louvain to Leiden : guaranteeing well-connected communities ». In : *Scientific Reports* 9.1 (2019), p. 5233. DOI : [10.1038/s41598-019-41695-z](https://doi.org/10.1038/s41598-019-41695-z).

- [25] Isaac VIRSHUP et al. « The AnnData object in single-cell omics ». In : *Genome Biology* (2021). Reference for the AnnData data structure.
- [26] Hui WAN, Liang CHEN et Minghua DENG. « scNAME : neighborhood contrastive clustering with ancillary mask estimation for scRNA-seq data ». In : *Bioinformatics* 38.6 (4 mars 2022). Sous la dir. de Christina KENDZIORSKI, p. 1575-1583. ISSN : 1367-4803, 1367-4811. DOI : [10.1093/bioinformatics/btac011](https://doi.org/10.1093/bioinformatics/btac011). URL : <https://academic.oup.com/bioinformatics/article/38/6/1575/6499267> (visité le 27/03/2026).
- [27] C. WANG, Z. CHEN et R. XI. « Feature screening for clustering analysis ». In : *arXiv preprint arXiv :2306.12671* (2023). URL : <https://arxiv.org/abs/2306.12671>.
- [28] Jing WANG et al. « scSCCNIA : similarity matrix based contrastive clustering with neighbor information aggregation for single-cell RNA sequencing data ». In : *Briefings in Bioinformatics* 27.2 (1^{er} mars 2026), bbag094. ISSN : 1467-5463, 1477-4054. DOI : [10.1093/bib/bbag094](https://doi.org/10.1093/bib/bbag094). URL : <https://academic.oup.com/bib/article/doi/10.1093/bib/bbag094/8507273> (visité le 27/03/2026).
- [29] F. Alexander WOLF, Philip ANGERER et Fabian J. THEIS. « Scanpy : large-scale single-cell gene expression data analysis ». In : *Genome Biology* 19.1 (2018), p. 15. DOI : [10.1186/s13059-017-1382-0](https://doi.org/10.1186/s13059-017-1382-0).
- [30] Ping XU et al. *scCDCG : Efficient Deep Structural Clustering for single-cell RNA-seq via Deep Cut-informed Graph Embedding*. 30 sept. 2025. DOI : [10.48550/arXiv.2404.06167](https://doi.org/10.48550/arXiv.2404.06167). arXiv : [2404.06167\[cs\]](https://arxiv.org/abs/2404.06167). URL : <http://arxiv.org/abs/2404.06167> (visité le 27/03/2026).
- [31] Yunpei XU et al. « scCAD : Cluster decomposition-based anomaly detection for rare cell identification in single-cell expression data ». In : *Nature Communications* 15.1 (2024), p. 7561. DOI : [10.1038/s41467-024-51891-9](https://doi.org/10.1038/s41467-024-51891-9).
- [32] Chenxin YI et al. « Benchmarking deep learning methods for biologically conserved single-cell integration ». In : *Genome Biology* 26.1 (20 nov. 2025), p. 398. ISSN : 1474-760X. DOI : [10.1186/s13059-025-03869-z](https://doi.org/10.1186/s13059-025-03869-z). URL : <https://doi.org/10.1186/s13059-025-03869-z> (visité le 14/04/2026).