

0.1 Introduction

Idée de la section

Présenter le laboratoire, le contexte et l’environnement de travail. Introduire le contexte biologique, les données scRNA-seq, le rôle du clustering et le problème spécifique des populations cellulaires rares.

Points à traiter

- Présenter les équipes, les GTs réalisés, les séminaires et réunions hebdomadaires.
- Rappeler ce que sont les données scRNA-seq et pourquoi elles permettent d’étudier l’hétérogénéité cellulaire à l’échelle d’une cellule.
- Expliquer le rôle du clustering dans l’identification de types cellulaires, de sous-types et de populations minoritaires.
- Présenter les difficultés des données : grande dimension, sparsity, bruit, dropout, effets de batch, déséquilibre entre populations cellulaires.
- Formuler le problème central : les populations rares contribuent peu aux objectifs moyens et peuvent être absorbées par des classes majoritaires ou par des types proches.
- Donner un exemple biologique concret : cellule immunitaire minoritaire, sous-type tumoral, population pathologique, population transitoire ou population spécifique d’un tissu.
- Expliquer l’impact biologique d’une population rare manquée : perte d’un signal d’intérêt, interprétation incomplète d’un tissu, confusion entre états cellulaires.
- Expliquer l’intérêt de rendre notre méthode inductive dans le contexte de médecine personnalisée.
- Annoncer les contributions du stage : SCRBenchmark, comparaison de l’état de l’art, développement de scRAW, optimisation, transfert de loss et premiers tests inductifs.

0.2 État de l’art

Idée de la section

Présenter les données, les étapes de preprocessing nécessaires, les algorithmes utilisés.

Objectif de la section

0.2.1 Données

- Décrire les caractéristiques des données scRNA-seq : matrice cellules-gènes, comptages bruts, normalisation, annotations cellulaires, métadonnées de batch.
- Présenter les types de datasets utilisés dans les papiers et dans le benchmark : pancréas, PBMC, rétine, testis, spleen ou autres jeux retenus.

- Préciser les critères importants pour comparer les méthodes : nombre de cellules, nombre de gènes, nombre de types cellulaires, présence de classes rares, nombre de batchs, espèce, tissu.
- Expliquer de l'origine de la vérité terrain : annotations manuelles, marqueurs connus, annotations héritées, incertitude biologique.
- Prévoir un tableau de synthèse des datasets avec taille, classes rares, batchs et protocole d'utilisation.

0.2.2 Traitements de données

Pré-process

- Présenter le prétraitement standard : filtrage des cellules et des gènes, normalisation, log-transformation, sélection des gènes hautement variables, scaling.
- Expliquer pourquoi ces choix modifient les résultats de clustering et doivent être fixés pour un benchmark reproductible.
- Discuter l'effet possible du prétraitement sur les populations rares : filtrage excessif, perte de gènes marqueurs, écrasement du signal minoritaire.
- Préciser quels éléments doivent être sauvegardés pour rejouer une analyse : paramètres de filtrage, gènes sélectionnés, transformation, modèle de scaling.

Batch effect

- Définir l'effet de batch : variation technique liée au protocole, à la plateforme, au laboratoire ou au moment d'acquisition.
- Expliquer pourquoi le batch peut dominer la structure biologique dans l'espace latent et perturber le clustering.
- Présenter les approches de correction ou d'intégration : ComBat, Harmony, Scanorama, scVI ou autres méthodes retenues.
- Discuter le risque inverse : sur-correction et disparition de différences biologiques réelles, en particulier pour les populations rares.
- Introduire la différence entre une évaluation transductive sur toutes les cellules et une évaluation inductive sur des batchs non vus.

0.2.3 Algorithmes de clustering

Approches classiques

- Présenter les pipelines classiques : réduction de dimension par PCA, construction d'un graphe de voisinage, clustering par K-Means, Louvain, Leiden ou HDBSCAN.
- Expliquer que PCA n'est pas un clustering en soi, mais une étape fréquente avant le clustering.
- Décrire les avantages : rapidité, simplicité, interprétabilité, intégration naturelle dans Scanpy et les workflows standards.

- Décrire les limites : sensibilité au prétraitement, difficulté à séparer des populations très proches, perte possible des petites populations dans les composantes principales ou dans le graphe.
- Positionner les méthodes de correction ou d'intégration associées : PCA + Harmony, PCA + ComBat, Scanorama puis clustering.

Approches deep learning

Les méthodes deep learning apprennent un espace latent avant le clustering. Le point important pour le rapport est de montrer ce qu'elles apportent par rapport aux pipelines classiques, puis pourquoi elles ne résolvent pas automatiquement le problème des populations rares.

Autoencodeurs (AE)

- Présenter le principe : encoder les profils d'expression dans un espace latent puis reconstruire l'entrée.
- Citer les familles pertinentes : autoencodeurs classiques, autoencodeurs variationnels, modèles de type scDeepCluster, DESC, scMAE, scNAME, scVI ou variantes proches.
- Expliquer l'intérêt : réduction non linéaire, débruitage, espace latent potentiellement plus adapté au clustering.
- Discuter les limites : coût de calcul, choix d'hyperparamètres, instabilité, dépendance au dataset, difficulté à préserver les classes rares si la loss est dominée par les populations majoritaires.

Graphes

- Présenter les méthodes qui exploitent explicitement un graphe cellule-cellule, gène-gène ou cellule-gène.
- Expliquer l'intérêt des GNN ou des approches graph-based : propagation d'information locale, structure de voisinage, meilleure modélisation des relations entre cellules.
- Discuter les limites : construction du graphe sensible au bruit et au batch, coût mémoire, difficulté à évaluer si le graphe améliore réellement la séparation des types rares.
- Relier ces approches aux pipelines classiques basés sur graphes de voisinage, afin de montrer la continuité entre Leiden/Louvain et les modèles profonds sur graphes.

Les types cellulaires dans les algorithmes

- Expliquer comment les types cellulaires sont utilisés selon les méthodes : non supervisé, semi-supervisé, supervisé, post-annotation ou contrainte biologique.
- Distinguer les labels de vérité terrain utilisés pour l'évaluation et les labels éventuellement utilisés pendant l'apprentissage.
- Présenter la question des classes rares : définition par proportion, difficulté d'évaluation, sensibilité aux métriques globales.

- Mentionner les approches dédiées aux populations rares ou aux sous-populations : GiniClust, CellSIUS ou méthodes apparentées si elles sont retenues dans la bibliographie.
- Introduire l'idée qui motive scRAW : augmenter l'influence des cellules rares ou peu denses dans l'objectif d'apprentissage.

0.3 Comparaison de l'existant

Question sur cette section : Est ce que ici je traite ce que j'ai fait sur Baron ? Ou est ce que je présente les résultats sur tous les datasets introduit dans l'état de l'art qui chronologiquement sont étudiés plus tard ? De manière plus globale, faut il vraiment laisser une description des datasets dans l'état de l'art, ne peut on pas la déplacer ici ?

Idée de la section

Montrer comment les méthodes existantes ont été rendues comparables : comment cela à était implémenté, protocole expérimental, métriques et premiers résultats. Cette section doit préparer la transition vers scRAW. L'idée est de montrer que les méthodes générale de DeepLearning et la PCA testées avaient des limites faces aux cellules rares et à l'effet batch. La section suivante détaillera les résultats de toutes les méthodes dont celles spécifiques à ces problématiques

0.3.1 Logiciel

- Présenter SCRBenchmark comme outil de benchmarking : chargement des données, sélection des méthodes, exécution, visualisation, export des résultats.
- Décrire les deux modes d'utilisation : interface interactive et ligne de commande et pourquoi.
- Présenter la structure logique : registre d'algorithmes, gestion des datasets, prétraitement, métriques, visualisations, sauvegarde des configurations.
- Expliquer pourquoi cet outil était nécessaire avant d'interpréter les résultats : homogénéiser les entrées, les sorties, les métriques et les figures.
- Mentionner les sorties sauvegardées : résultats bruts, tableaux agrégés, embeddings, labels prédits, figures, configurations et logs.
- Discuter l'apport pratique : reproductibilité, traçabilité, comparaison plus simple pour des utilisateurs non spécialistes du code.

0.3.2 Expériences

Données et splits

- Présenter les jeux de données retenus : nom, espèce, tissu, nombre de cellules, nombre de gènes, nombre de classes, classes rares, batches.
- Expliquer les critères de sélection : diversité des tissus, présence de populations rares, disponibilité de labels, présence ou non d'effet batch.
- Décrire les splits utilisés : transductif, train/test par batch, leave-one-batch-out ou autre protocole retenu.

- Indiquer comment les classes rares sont définies pour les métriques RareACC et UltraRareACC.
- Prévoir un tableau dédié aux datasets et aux splits.

Méthodes

- Lister les méthodes comparées : PCA + Leiden, Harmony, ComBat, Scanorama, DESC, scMAE, scNAME, scVI
- Préciser les choix d’hyperparamètres et les étapes de preprocessing
- Expliquer les contraintes pratiques : méthodes difficiles à installer, différences PyTorch/TensorFlow, temps de calcul,
- Décrire les métriques : ARI, NMI, ACC, BalancedACC, RareACC, UltraRareACC, temps d’exécution
- Justifier pourquoi une seule métrique globale ne suffit pas pour juger la conservation des populations rares. Montrer pour cela une matrice de confusion. L’idée est de se rendre compte du manque de performances pour des populations minoritaires et si il y a de l’effet batch.

Résultats

- Présenter un tableau global des scores par méthode et par dataset.
- Identifier les familles qui fonctionnent bien globalement et celles qui préservent mieux les populations rares.
- Comparer performance globale et performance rare pour montrer les compromis.
- Montrer les UMAP comparatifs, matrices de confusion (et temps de calcul).
- Conclure sur les limites observées qui motivent le développement de scRAW.

0.4 scRAW

0.4.1 Positionnement et motivation

- Présenter scRAW comme une réponse aux limites observées dans la comparaison de l’existant.
- Expliquer l’objectif : apprendre un espace latent qui conserve les structures globales tout en donnant plus d’importance aux populations rares ou peu denses tout en prévenant l’effet batch de manière interne à l’algorithme.
- Distinguer scRAW des méthodes classiques et des autoencodeurs standards : pondération dynamique, objectif rare-aware, possibilité d’intégrer d’autres pertes.
- Formuler clairement l’hypothèse : si les cellules minoritaires pèsent davantage pendant l’apprentissage, elles ont plus de chances de rester séparables dans l’espace latent.

0.4.2 Pipeline

- Décrire les étapes : prétraitement, autoencodeur, espace latent, estimation de rareté ou de densité, pondération, pertes d'apprentissage, clustering final.
- Présenter les sorties : embeddings, labels prédits, poids cellulaires, modèle entraîné, figures, métriques.
- Expliquer le rôle de chaque bloc dans le pipeline et les paramètres importants.
- Prévoir un schéma complet du pipeline scRAW.

0.4.3 Fonctions de perte et variantes

- Décrire la loss de reconstruction pondérée et son lien avec les populations rares.
- Présenter les variantes testées : pondération dynamique, DANN, triplet loss, fine-tuning ou autres variantes effectivement retenues.
- Expliquer comment les poids cellulaires sont calculés ou mis à jour.
- Discuter les compromis : amélioration des rares, stabilité globale, sensibilité aux hyperparamètres.

0.4.4 Recherche d'hyperparamètres

- Décrire ce qui a été exploré : architecture, dimension latente, epochs, force de pondération, clustering final, pertes, prétraitement latent.
- Préciser la stratégie : recherche large, ablations ciblées, consolidation finale, répétitions avec plusieurs seeds.
- Expliquer les critères de sélection : score global, RareACC, UltraRareACC, BalancedACC, stabilité.
- Montrer les configurations qui améliorent les rares, celles qui échouent et celles qui créent un mauvais compromis.
- Prévoir une figure Optuna ou un tableau d'ablation.

0.4.5 Résultats et discussion

- Comparer scRAW aux meilleures méthodes de l'état de l'art sur les datasets retenus.
- Montrer les gains et les limites : scores, UMAP, matrices de confusion, visualisation des poids cellulaires.
- Discuter le comportement sur classes rares, classes fréquentes et batchs difficiles.
- Présenter le coût de calcul et les difficultés rencontrées.
- Terminer par ce que scRAW valide et ce qui reste fragile avant les extensions.

0.5 Travaux complémentaires

Idée de la section

Regrouper les différentes expériences complémentaires : transfert de la loss et passage à un mode inductif.

0.5.0 Transfert de loss

- Présenter l'idée : transférer la loss de reconstruction pondérée ou la logique rare-aware vers d'autres algorithmes de deep learning.
- Expliquer pourquoi c'est intéressant : séparer la contribution méthodologique de scRAW de son architecture précise.
- Décrire le protocole expérimental : méthodes ciblées, variantes avec et sans loss transférée, datasets, métriques.
- Montrer les premiers résultats : gains, échecs, stabilité, coût.
- Discuter les limites : compatibilité des architectures, difficulté d'intégration, risque de sur-pondération des petites populations.

0.5.1 Induction

- Distinguer transductif et inductif : entraîner sur un ensemble de cellules puis prédire ou projeter de nouvelles cellules non vues.
- Décrire le protocole : train sur certains batchs, gel du prétraitement et du modèle, prédiction sur batchs non vus.
- Préciser les artefacts sauvegardés : modèle, état du prétraitement, gènes retenus, centroïdes de référence, configuration.
- Expliquer pourquoi l'inductif rapproche scRAW d'un usage réel : nouvelles cellules, nouveau batch, réanalyse rapide sans tout réentraîner.
- Présenter les résultats comparant inductif et transductif lorsque c'est possible.
- Discuter les limites : batch non représentatif, classes absentes du train, baisse possible des performances rares.

0.5.2 Interprétation biologique ?

- À définir

Conclusion finale à rédiger

- Résumer les contributions : SCRBenchmark, comparaison standardisée, scRAW, optimisation et premières extensions.
- Revenir à la question directrice : préserver les populations rares sans sacrifier entièrement la performance globale.

- Présenter les limites : taille des datasets, vérité terrain, sensibilité aux hyperparamètres, coût de calcul, validation biologique.
- Ouvrir sur les perspectives : stabilisation de l'inductif, transfert de loss, validation par marqueurs, intégration dans un workflow utilisateur.

Figures et tableaux à préparer

- **Tableau État de l'art**
- **Schéma général du pipeline de benchmarking**
- **Capture ou schéma de SCRBenchmark :**
- **Tableau des jeux de données**
- **Tableau des méthodes comparées :** Lors des premiers nous n'avons pas testés toutes les méthodes décrites, comment le justifier ?
- **Tableau des métriques :**
- **Tableau ou figures principal des performances :**
- **UMAP comparatifs :**
- **Matrices de confusion :**
- **Schéma du pipeline scRAW :**
- **Visualisation des poids cellulaires de scRAW :**
- **Tableau d'ablation :** variantes de scRAW, pertes, poids, clustering final.
- **Figure de recherche d'hyperparamètres :** résumé Optuna ou graphiques montrant le compromis entre performance globale, performance rare et stabilité.
- **Figure inductive :**
- **Tableau du coût de calcul :**
- **Figure ou tableau d'analyse biologique :**